

PageRank su Architetture Ibride

Parallelizzazione con OpenMP e CUDA

Emanuele Cecchia

Corso di Programmazione su Architetture Parallele

A.A. 2025–26 — Prof. Andrea Formisano

6 ottobre 2026

Abstract

Il progetto implementa e analizza l'algoritmo PageRank su architetture parallele, confrontando tre versioni: una sequenziale, che fa da riferimento per ogni misura di speed-up, una puramente multicore basata su OpenMP e una ibrida che distribuisce il carico fra CPU e GPU tramite CUDA. Sequenziale e OpenMP condividono lo stesso file sorgente e differiscono solo per le opzioni di compilazione, così che il riferimento non possa divergere dal codice parallelo né essere falsato dai costi di gestione dei thread. Il grafo è memorizzato trasposto in formato CSR, scelta che rende il nucleo di calcolo privo di scritture concorrenti e quindi parallelizzabile senza sincronizzazione. La correttezza è verificata contro tre implementazioni indipendenti. Le misure sulla versione OpenMP, condotte su nove grafi reali e due processori, mostrano uno speed-up di 2,6–3,5× su 4 core e di 6,9–11,9× su 12 e, soprattutto, una saturazione oltre il numero di core fisici che identifica il calcolo come *memory-bound*: è questo il dato che motiva quantitativamente il passaggio alla GPU.

[DA COMPLETARE] Aggiornare l'abstract con i risultati CUDA una volta completata la fase ibrida.

Indice

1	Descrizione del problema affrontato	3
1.1	Il problema	3
1.2	Damping factor e Dangling Mass	3
1.3	Forma matriciale	4
1.4	Algoritmo	4
1.5	Necessità della parallelizzazione	5
2	Metodologia adottata per la soluzione	5
2.1	Struttura del codice	5
2.2	Rappresentazione dei dati: CSR	6
2.3	Formato binario e pre-elaborazione	8
2.4	Precisione: <code>float</code> contro <code>double</code>	10
2.5	Validazione del file in ingresso	10
2.6	Implementazione sequenziale e OpenMP	11
2.7	Implementazione ibrida OpenMP + CUDA	12
2.8	Strategia di verifica	12

3	Risultati sperimentali	14
3.1	Ambienti di prova	14
3.2	Istanze di prova	14
3.3	Correttezza	15
3.4	Misura dei tempi	15
3.5	Scalabilità della versione OpenMP	16
3.6	Confronto fra le varianti <code>float</code> e <code>double</code>	19
3.7	Risultati della versione ibrida	20
4	Valutazioni e osservazioni	20
4.1	Punti di forza	20
4.2	Punti deboli e limiti	21
4.3	Possibili miglioramenti	21
4.4	Codice sorgente e guida all'uso	22

1 Descrizione del problema affrontato

1.1 Il problema

PageRank assegna a ogni nodo di un grafo orientato un punteggio di importanza, definito ricorsivamente: un nodo è importante se nodi importanti puntano ad esso. Nato per ordinare le pagine web in base alla struttura dei collegamenti ipertestuali [1], viene oggi applicato anche a reti sociali, reti di citazioni e reti biologiche.

La definizione è ricorsiva e si risolve iterativamente: si parte da una distribuzione uniforme e la si raffina finché non cambia più — in pratica, finché la variazione non scende sotto una soglia prefissata, oppure fino a un numero massimo di iterazioni. Equivale al modello del *navigatore casuale*, che segue collegamenti scelti a caso: il PageRank è la frazione di tempo che costui trascorre su ciascuna pagina. Ne discendono due proprietà della formula — il totale vale 1, perché il navigatore è sempre da qualche parte, e un collegamento pesa tanto meno quanti più ne partono dalla stessa pagina.

Formalmente, dato un grafo orientato $G = (V, E)$ con $N = |V|$,

$$\text{PR}_{t+1}(v) = \frac{1-d}{N} + d \left(\sum_{u: u \rightarrow v} \frac{\text{PR}_t(u)}{\text{outdeg}(u)} + \frac{\text{dangling}_t}{N} \right) \quad (1)$$

dove i simboli hanno il seguente significato:

$\text{PR}_t(v)$	<i>PageRank</i> : punteggio del nodo v alla t -esima iterazione
$\text{outdeg}(u)$	numero di archi uscenti da u
d	<i>damping factor</i> , convenzionalmente 0,85
dangling_t	<i>dangling mass</i> : punteggio complessivo dei nodi senza archi uscenti $\text{dangling}_t = \sum_{u: \text{outdeg}(u)=0} \text{PR}_t(u)$
N	numero di nodi

1.2 Damping factor e Dangling Mass

Il termine $(1-d)/N$: un gruppo di pagine che si citano solo fra loro assorbirebbe, iterazione dopo iterazione, tutto il punteggio del grafo, perché i collegamenti vi entrano e nessuno ne esce. Con probabilità $1-d$ il navigatore abbandona i collegamenti e salta su una pagina qualsiasi: questo impedisce l'accumulo e rende ogni nodo raggiungibile da ogni altro. È anche l'unica via d'uscita da un nodo senza archi uscenti, dove con $d=1$ il navigatore resterebbe intrappolato per sempre.

Il termine $\text{dangling}_t/N$: un nodo senza archi uscenti non ha modo di ridistribuire il proprio rank. Il salto casuale lo libera con probabilità $1-d$, ma la quota d restante cercherebbe un collegamento che non esiste: è questa che il termine raccoglie e ridistribuisce. Ignorandolo, ad ogni iterazione una frazione della massa totale sparirebbe e il vettore cesserebbe di essere una distribuzione di probabilità. Nei dataset utilizzati questo non è un caso limite: sono *dangling* il 15,6% dei nodi di *web-Google*, il 44,6% di *cit-Patents* e il 57,7% di *web-NotreDame* (Tabella 2). La conseguenza pratica è che $\sum_v \text{PR}(v) = 1$ costituisce un test di correttezza.

Con entrambi i termini l'iterazione descrive una catena di Markov sui nodi del grafo: da ogni nodo — cicli chiusi e vicoli ciechi compresi — si può sempre raggiungere qualunque altro. Questo ci garantisce un'unica distribuzione stazionaria.

1.3 Forma matriciale

La stessa iterazione si scrive in forma vettoriale. Sia $\mathbf{MT} \in \mathbb{R}^{N \times N}$ la *matrice di transizione* definita da

$$\mathbf{MT}_{vu} = \begin{cases} 1/\text{outdeg}(u) & \text{se esiste l'arco } u \rightarrow v, \\ 0 & \text{altrimenti,} \end{cases} \quad (2)$$

e sia $\mathbf{1}$ il vettore di tutti uni. Detto $\mathbf{PR}_t$ il vettore dei punteggi ($\text{PR}(1), \dots, \text{PR}(N)$), l'iterazione (1) diventa

$$\mathbf{PR}_{t+1} = \frac{1-d}{N} \mathbf{1} + d \left(\mathbf{MT} \mathbf{PR}_t + \frac{\text{dangling}_t}{N} \mathbf{1} \right), \quad \text{dangling}_t = \mathbf{w}^\top \mathbf{PR}_t \quad (3)$$

dove $\mathbf{w}$ è il vettore indicatore dei nodi dangling ($w_u = 1$ se $\text{outdeg}(u) = 0$, altrimenti 0).

Il prodotto $\mathbf{MT} \mathbf{PR}_t$ che compare nella (3) è una moltiplicazione matrice-sparsa per vettore (SpMV, Sparse Matrix-Vector Multiplication): una matrice sparsa moltiplica un vettore denso e ne produce uno nuovo, sempre denso, nella forma generica $\mathbf{y} = \mathbf{Ax}$. È questa l'operazione che il progetto parallelizza. Per non pagare gli zeri né in spazio né in tempo si memorizzano i soli elementi non nulli di $\mathbf{MT}$, usando formati come CSR (Compressed Sparse Row), che vedremo nella Sezione 2.2.

1.4 Algoritmo

Algorithm 1 PageRank per iterazione di potenza (formulazione *pull*)

```

1:  $\text{PR}[v] \leftarrow 1/N$  per ogni  $v \in V$ 
2: repeat
3:    $\text{dangling} \leftarrow 0$ 
4:   for all  $u \in V$  do
5:     if  $\text{outdeg}[u] = 0$  then
6:        $\text{contrib}[u] \leftarrow 0$ ;  $\text{dangling} \leftarrow \text{dangling} + \text{PR}[u]$ 
7:     else
8:        $\text{contrib}[u] \leftarrow \text{PR}[u]/\text{outdeg}[u]$ 
9:     end if
10:  end for
11:   $\text{base} \leftarrow (1-d)/N + d \cdot \text{dangling}/N$ 
12:  for all  $v \in V$  do
13:     $\text{PR}'[v] \leftarrow \text{base} + d \sum_{u \rightarrow v} \text{contrib}[u]$ 
14:  end for
15:   $\varepsilon \leftarrow \sum_v |\text{PR}'[v] - \text{PR}[v]|$ 
16:  scambia  $\text{PR}$  e  $\text{PR}'$ 
17: until  $\varepsilon < \text{tolleranza}$ 

```

N, d	numero di nodi e damping factor: scalari, costanti per tutta l'esecuzione
$PR[v]$	punteggio corrente del nodo v ; PR è un vettore di N componenti, una per nodo
$PR'[v]$	punteggio di v calcolato nell'iterazione in corso; vettore di appoggio, della stessa forma di PR
$contrib[u]$	contributo che u manda lungo ciascuno dei suoi archi uscenti; vettore di N componenti, ricalcolato ad ogni iterazione
$outdeg[u]$	numero di archi uscenti da u ; vettore di N componenti, proprietà fissa del grafo
$dangling$	<i>dangling mass</i> : scalare, punteggio complessivo dei nodi senza archi uscenti
$base$	scalare, quota di punteggio che spetta a ogni nodo indipendentemente dagli archi
ε	scalare, variazione complessiva fra un'iterazione e la successiva

Ogni iterazione ricostruisce il vettore dei punteggi a partire da quello precedente, con due passaggi sui nodi. Nel primo ogni nodo è visto come sorgente: si calcola quanto manda lungo ciascun arco uscente e si raccoglie al tempo stesso la *dangling mass*. Nel secondo ogni nodo è visto come destinazione: si sommano i contributi che arrivano dai suoi predecessori. Si ripete finché la variazione complessiva non scende sotto la tolleranza. Il ciclo è il *metodo delle potenze*: si rimoltiplica il vettore finché non si stabilizza, e non serve normalizzarlo a ogni passo perché l'iterazione conserva da sé la somma a 1. *Pull* indica invece che ogni nodo legge dai predecessori anziché scrivere nei successori, scelta motivata nella Sezione 2.2.

Esplicitando *base*, il calcolo di $PR'[v]$ è esattamente l'iterazione (1):

$$PR'[v] = \underbrace{\frac{1-d}{N} + d \frac{dangling}{N}}_{base} + d \sum_{u: u \rightarrow v} contrib[u]$$

dove $contrib[u] = PR[u]/outdeg[u]$ per i nodi con archi uscenti, e $contrib[u] = 0$ per i *dangling*, il cui punteggio confluisce invece in *dangling*.

Il calcolo di $contrib[u]$ — il primo ciclo, quello dei *contributi* — è separato dal secondo, quello di *accumulo*, per una ragione di costo: eseguito così richiede N divisioni per iterazione anziché $M = |E|$, e nei grafi considerati $M \gg N$ (su `soc-LiveJournal1`, 69 milioni contro 4,8 milioni). La divisione è fra le operazioni aritmetiche più lente, quindi il risparmio è reale.

1.5 Necessità della parallelizzazione

La difficoltà del problema è interamente di scala. La matrice **MT** della Sezione 1.3 è *sparsa*: delle sue N^2 celle solo M sono diverse da zero, e nei grafi reali $M \ll N^2$. Rappresentarla come matrice densa $N \times N$ — una cella per ogni coppia (v, u) — richiederebbe una memoria quadratica in N e occupata quasi per intero da zeri, oltre a N^2 moltiplicazioni per iterazione anziché M . Si adotta perciò una rappresentazione *sparsa*, che conservi i soli elementi non nulli — il formato **CSR** della Sezione 2.2. Restano comunque M archi da percorrere a ogni iterazione, e le iterazioni si susseguono fino a convergenza: questo rende necessario distribuire il calcolo su più unità di elaborazione.

2 Metodologia adottata per la soluzione

2.1 Struttura del codice

Il progetto si compone di nove moduli, dei quali due soli formano il programma di calcolo vero e proprio: `src/pagerank.c`, che contiene il nucleo cronometrato, e `src/csr.c`, che porta il grafo

in memoria prima che il cronometro parta. Gli altri preparano i dati, guidano l'esecuzione o servono a controllare i risultati.

Modulo	Ruolo
tools/snap_to_csr.py	conversione SNAP $\rightarrow$ CSR binario
src/csr.c, csr.h	caricamento e validazione
src/pagerank.c, .h	nucleo di calcolo
src/main.c	programma principale, output, log dei tempi
src/csr_info.c	statistiche di un grafo convertito
tools/verify_pagerank.py	verifica indipendente
tools/run_benchmarks.sh	misure su tutte le configurazioni
tools/plot_results.py	figure di scalabilità
tools/locality_stats.py	statistiche di località del gather

2.2 Rappresentazione dei dati: CSR

Per rappresentare i soli elementi non nulli della matrice **MT**, il formato **CSR** non usa una matrice bidimensionale $N \times N$ ma tre array monodimensionali:

- `col_idx[M]`: gli indici di colonna dei non nulli, letti riga per riga;
- `row_ptr[N+1]`: `row_ptr[v]` è la posizione, dentro `col_idx`, in cui comincia la riga v ;
- `out_deg[N]`: il grado uscente di ogni nodo, cioè il denominatore $\text{outdeg}(u)$ della (1).

La Figura 1 segue la costruzione su un grafo di cinque nodi e otto archi, dal grafo alla matrice agli array.

Tutto ruota attorno a `row_ptr`: gli elementi della riga v sono `col_idx[row_ptr[v] ... row_ptr[v+1]-1]`, e la lunghezza della riga è la differenza fra due offset consecutivi, che quindi non va memorizzata a parte. Nell'esempio della figura la riga 2 comincia in posizione `row_ptr[2] = 4` e finisce prima di `row_ptr[3] = 7`: i predecessori del nodo 2 sono dunque `col_idx[4]`, `col_idx[5]` e `col_idx[6]`, cioè i nodi 0, 1 e 4 — come si può constatare nel grafo. Gli offset sono $N + 1$ e non N proprio per questo motivo: la sentinella `row_ptr[N] = M` fa sì che l'ultima riga si tratti come tutte le altre.

Perché manca l'array dei valori. In un CSR generico il terzo array è `val[M]`, con il valore di ogni elemento non nullo; qui al suo posto c'è `out_deg[N]`. Il motivo si legge nella Figura 1(b): tutti i non nulli della colonna u valgono $1/\text{outdeg}(u)$, così che il valore dipenda dalla sola colonna e sia ricavabile da `out_deg`. Ricavarlo a ogni accesso costerebbe però una divisione per arco: dentro `col_idx` ogni nodo u compare tante volte quanti sono i suoi archi uscenti, e ognuna rifarebbe la stessa divisione. Nell'esempio della Figura 1 il nodo 1 compare tre volte, una per ciascuno dei suoi tre archi uscenti, e il quoziente $\text{PR}(1)/3$ verrebbe ricalcolato identico tutte e tre le volte, perché né $\text{PR}(1)$ né $\text{outdeg}(1)$ cambiano durante l'iterazione. Il vettore `contrib` dell'Algoritmo 1 esegue invece la divisione una volta per nodo, in un passaggio separato che precede quello sui predecessori: a quest'ultimo resta solo da leggere `contrib[col_idx[j]]` e sommarlo, senza divisioni e senza valori da recuperare. Anche in memoria il guadagno viene dallo stesso passaggio da M a N , con $N \ll M$: su `soc-LiveJournal1` un `val[M]` in doppia precisione occuperebbe $8 \times M$ byte, cioè circa 526 MiB, mentre a `out_deg` bastano $4 \times N$ byte, circa 18,5 MiB: quasi trenta volte meno.




Figura 1: Costruzione del CSR del grafo trasposto, su un esempio con $N = 5$ nodi e $M = 8$ archi. In (b) la riga v della matrice $\mathbf{MT}$ raccoglie i *predecessori* di v , e ogni colonna u ha il valore costante $1/\text{outdeg}(u)$. In (c) `col_idx` concatena le righe di (b), `row_ptr[v]` indica dove ciascuna comincia e `out_deg` conserva i denominatori. Le due condizioni limite sono distinte e vivono su array distinti: la riga 4 è vuota perché nessuno punta al nodo 4, mentre `out_deg[3]` è nullo perché il nodo 3 non ha archi uscenti.

Perché il trasposto. Importante la scelta di quale indice diventa la riga. L'equazione (1) richiede, per calcolare $PR_{t+1}(v)$, l'insieme dei nodi che puntano a v . Esistono due modi di organizzare il calcolo:

Push si scorre l'insieme degli archi $u \rightarrow v$ e si somma il contributo di u dentro $PR'(v)$. Più archi convergono sullo stesso v , quindi più thread scrivono sulla stessa cella: si genera una *race condition* che richiede operazioni atomiche o lock.

Pull si scorre l'insieme dei nodi v , si leggono i suoi predecessori e si scrive $PR'(v)$ una sola volta. Ogni nodo è di competenza di un solo thread: **non esiste alcuna scrittura concorrente**.

È stata adottata la formulazione *pull*, che richiede di memorizzare, per ogni nodo, la lista dei predecessori — cioè il grafo con tutti gli archi invertiti, il *trasposto*. È quanto illustra la Figura 1: la riga v raccoglie gli archi *entranti* in v , non quelli uscenti. L'inversione non richiede un passo dedicato: costruendo il CSR si sceglie semplicemente il nodo di destinazione, anziché quello di origine, come indice di riga.

Costo in memoria e modo di accesso. La struttura occupa $8 \times (N+1) + 4 \times M + 4 \times N$ byte, ed è questa formula a produrre l'ultima colonna della Tabella 2: per **web-Google** 29,5 MiB contro i 5,6 TiB della matrice densa. Resta però un aspetto importante: il ciclo tocca tre array, e li tocca in due modi diversi. `row_ptr` e `col_idx` si leggono in ordine, $v = 0, 1, 2, \dots$ e dentro ogni riga $j = 0, 1, 2, \dots$; il processore se ne accorge e fa *prefetch*,¹ cosicché quando si arriva a quelle celle siano già in cache e l'attesa sia quasi nulla. Con `contrib[col_idx[j]]` non succede: l'indice arriva da `col_idx`, quindi all'interno di una riga i nodi sono ordinati in ordine crescente, ma la distanza tra un indice e il successivo è imprevedibile — nell'esempio della Figura 1, per la riga/nodo 0, prima `contrib[1]`, poi `contrib[4]` — e il prefetch non ha modo di indovinare quanto. Ogni accesso rischia così di aspettare la RAM, molto più lenta della cache.

Per ogni arco si va a prendere un contributo in una posizione imprevedibile e si esegue una sola somma: tanto traffico di memoria, pochissima aritmetica. In teoria il calcolo dovrebbe risultare *memory-bound*, e la Sezione 3.5 verifica se è davvero così.

2.3 Formato binario e pre-elaborazione

I grafi della collezione SNAP sono distribuiti come file di testo. Dopo l'intestazione seguono gli archi, uno per riga, come due interi separati da un carattere di tabulazione:

```
# Directed graph (each unordered pair of nodes is saved once): Wiki-Vote.txt
# Wikipedia voting on promotion to administratorship (till January 2008).
...
# Nodes: 7115 Edges: 103689
# FromNodeId      ToNodeId
30                1412
30                3352
30                5254
```

Il primo intero è il nodo di partenza, il secondo quello di arrivo: ogni riga è dunque un arco orientato. Non c'è un elenco esplicito dei nodi — esistono quelli che compaiono in almeno un arco — e il formato non garantisce né che gli identificatori siano contigui, né che le righe siano ordinate, né che uno stesso arco non compaia due volte.

¹Riconosciuto un andamento regolare negli accessi alla memoria, il processore porta in cache le celle successive prima che il programma le chieda. Funziona sugli accessi sequenziali; su quelli imprevedibili non ha nulla su cui basarsi.

La conversione dal formato testuale SNAP al CSR avviene *una volta sola*, offline: l'analisi del testo è lenta e irregolare, ed eseguirla dentro il programma misurato significherebbe misurare il parser anziché l'algoritmo. Si tratta di sola preparazione dei dati e il risultato è l'input del programma vero e proprio, non una sua parte: il convertitore `tools/snap_to_csr.py` è scritto in Python per comodità, dato che numpy risolve in poche righe la rimappatura degli identificatori e l'ordinamento degli archi.

Gli identificatori SNAP sono sparsi (`web-Google` ha 875 713 nodi con id fino a 916 428) e vengono rimappati su un intervallo contiguo $[0, N)$; la corrispondenza inversa è salvata in un file `.ids` separato, letto solo per riportare i risultati negli identificatori originali.

Per conservare il risultato si è scelto un formato binario invece che testuale. Due ragioni a favore:

- *velocità*: leggere il binario è solo copiare byte,² perché i byte del file sono già nella forma in cui il programma li usa, senza niente da interpretare, mentre in testo servirebbe un parser in C che a ogni esecuzione rilegga e riconverta i numeri cifra per cifra;
- *dimensione*: in binario un numero occupa i byte del suo tipo, in testo un carattere per cifra più il separatore.

E due prezzi da pagare:

- *leggibilità*: il file non si apre con un editor per dargli un'occhiata; per guardare dentro un grafo convertito serve uno strumento apposta, ed è `src/csr_info.c`;
- *errori silenziosi*: qualunque sequenza di byte può essere un CSR valido, sicché un file corrotto o troncato viene letto lo stesso e produce risultati sbagliati senza avvisare. Un testo malformato invece è più facile da rilevare: chi lo legge trova un carattere dove si aspettava una cifra, e si ferma. È per questo che `src/csr.c` ha il magic number e i cinque controlli della Sezione 2.5.

Il grafo è scritto in un file `.csr`, nel formato binario seguente:

Campo	Tipo	Dimensione
magic "PRCSR001"	char[8]	8 byte
n_nodes	uint64	8 byte
n_edges	uint64	8 byte
row_ptr	uint64[]	$8(N+1)$ byte
col_idx	uint32[]	$4M$ byte
out_deg	uint32[]	$4N$ byte

I primi otto byte identificano il formato: il caricatore li confronta e rifiuta subito un file che non sia un `.csr`, invece di interpretarne i primi byte come dimensioni. Le tre cifre finali sono un numero di versione.

Per ciascuno dei tre array resta da decidere quanti byte dare a ogni singolo numero, 4 oppure 8. Servono due informazioni, ed è bene tenerle distinte: *quante celle* ha l'array, che dice quanto si guadagna a stringerlo, e *quanto valgono* i numeri che vi finiscono dentro, che dice se stringerlo è possibile. In 4 byte sta qualunque valore fino a circa 4,3 miliardi.

Array	Celle	Contenuto di una cella	Valore massimo
col_idx	M , una per arco	l'indice di un nodo	$N - 1$
row_ptr	$N+1$, una per nodo	una posizione dentro col_idx	M
out_deg	N , una per nodo	il grado uscente del nodo	$N - 1$

²Il caricamento si riduce a una `fread` per array.

Le prime due righe sono incrociate: `col_idx` ha molte celle e valori piccoli, `row_ptr` poche celle e valori grandi. Su `soc-LiveJournal1` le celle sono 69 milioni (archi) contro 4,8 milioni (nodi).

`col_idx` usa perciò 32 bit. Si può, perché dentro ci sono indici di nodo e il più alto è solo 4847571. E conviene, perché le celle sono M : i 4 byte risparmiati su ognuna valgono 263 MiB su un file che in tutto ne pesa 318,7. `row_ptr` resta invece a 64 bit. Stringerlo sarebbe possibile — 69 milioni in 4 byte ci sta — ma rende poco e costa un limite. Rende poco perché le celle sono quattordici volte meno: 18 MiB invece di 263. Costa un limite perché dentro ci sono posizioni nell'array degli archi, che crescono velocemente con M . `out_deg` sta a 32 bit come `col_idx`, perché ha un valore massimo che non supera N , e in più la scelta pesa poco perché, come `row_ptr`, ha N celle. Il tipo stretto va insomma dove le celle sono tante e i valori piccoli, quello largo dove le celle sono poche e i valori possono crescere.

Il guadagno atteso, poi, non è tanto sul disco quanto sul traffico di memoria: per ogni arco il ciclo legge un elemento di `col_idx` ed esegue una sola moltiplicazione-somma, cosicché portare ogni cella da 8 a 4 byte dimezza i byte letti in sequenza.

2.4 Precisione: float contro double

Bisogna decidere anche quanti byte dare a ogni numero dei tre vettori dell'Algoritmo 1 — `PR`, `PR'` e `contrib` — che non fanno parte del `.csr` ma vivono solo in memoria, e condividono un unico tipo, definito da un `typedef` che si può cambiare in fase di compilazione con `-DPAGERANK_FLOAT`. La motivazione è che sulle GPU di fascia consumer l'aritmetica FP32 (`float`, 4 byte) è nettamente più veloce della FP64 (`double`, 8 byte). Il kernel CUDA richiederà perciò verosimilmente `float`; mantenere entrambe le varianti raggiungibili dallo stesso sorgente permette di confrontarne accuratezza e velocità.

Gli accumulatori — `accum_t` nel codice — restano invece sempre in `double`. Sono tre sole variabili scalari: la somma dei contributi di un nodo, la massa dangling e la variazione ε fra due iterazioni. Tenerle larghe non costa quindi traffico di memoria, mentre stringerle costerebbe accuratezza.

2.5 Validazione del file in ingresso

Il caricatore in `src/csr.c` verifica cinque proprietà del file prima di dichiarare riuscito il caricamento:

- `check_header_counts` — i conteggi dichiarati sono compatibili con la dimensione del file;
- `check_header_size` — il file misura esattamente quanto l'intestazione implica;
- `check_rowptr_span` — i due estremi di `row_ptr`: il primo offset vale 0, l'ultimo vale M ;
- `check_rowptr_monotonic` — gli offset non decrescono, il che insieme al controllo precedente li confina tutti in $[0, M]$;
- `check_neighbours_are_existing_nodes` — ogni vicino memorizzato è un nodo esistente.

I controlli fatti in fase di caricamento permettono al programma di assumere che i dati siano corretti e di non verificare nulla dentro i cicli di calcolo (`pagerank.c`).

2.6 Implementazione sequenziale e OpenMP

Le due versioni condividono lo stesso file sorgente `pagerank.c` poiché le direttive OpenMP sono ignorate dal compilatore quando non gli si passa `-fopenmp`, che produce quindi un programma sequenziale. Oltre a non esistere così duplicazione di codice che possa divergere, il riferimento sequenziale è *onesto*: misurando la versione parallela limitata a un thread si otterrebbe un tempo peggiore (Tabella 4 e Tabella 5, colonna a un thread, sette grafi su otto su entrambe le macchine), perché si pagherebbe comunque la creazione del team di thread: usarla come riferimento gonfierebbe silenziosamente ogni speed-up dichiarato.

Il nucleo contiene due cicli paralleli per iterazione.

```
1 | #pragma omp parallel for schedule(static) reduction(+ : dangling)
2 | for (v = 0; v < n; v++) {
3 |     if (g->out_deg[v] == 0) {
4 |         contrib[v] = 0;
5 |         dangling += cur[v];
6 |     } else {
7 |         contrib[v] = cur[v] / g->out_deg[v];
8 |     }
9 | }
```

Listing 1: Calcolo dei contributi e massa dangling.

La clausola `reduction(+ : dangling)` assegna a ogni thread una copia privata della variabile, inizializzata a zero, e ne somma i valori al termine del ciclo. È la soluzione corretta e veloce al problema dell'aggiornamento concorrente: una variabile condivisa protetta da lock serializzerebbe l'intero ciclo. Lo scheduling è `static` perché il lavoro per iterazione è costante.

```
1 | #pragma omp parallel for schedule(dynamic, 256) reduction(+ : error)
2 | for (v = 0; v < n; v++) {
3 |     accum_t sum = 0.0;
4 |     for (j = g->row_ptr[v]; j < g->row_ptr[v + 1]; j++)
5 |         sum += contrib[g->col_idx[j]];
6 |     nxt[v] = base + d * sum;
7 |     error += fabs(nxt[v] - cur[v]);
8 | }
```

Listing 2: Accumulo dai predecessori (CSR).

La clausola `reduction` su `error` funziona allo stesso modo, mentre lo scheduling è `dynamic`: la lunghezza delle righe varia di ordini di grandezza, quindi una suddivisione statica assegnerebbe a ogni thread lo stesso *numero di righe* ma non la stessa *quantità di lavoro*, lasciando inattivi i thread che hanno ricevuto solo nodi di grado basso. La dimensione del blocco (256) è un parametro che va calibrato provando.

Alternanza dei buffer. L'iterazione alterna due vettori (`rank` e `next`) scambiando due puntatori (`cur`, che indica sempre i punteggi più recenti, e `nxt`, dove si scrivono quelli nuovi) anziché copiare i dati; una sola `memcpy` finale è necessaria, e solo se il numero di scambi è dispari.

2.7 Implementazione ibrida OpenMP + CUDA

[DA COMPLETARE] Sezione da scrivere interamente. Dovrà documentare: partizionamento del carico fra V_{host} e V_{device} in base al grado dei nodi; copiare i dati sulla GPU mentre il calcolo è già in corso, usando stream creati esplicitamente e `cudaMemcpyAsync`; combinazione dell'errore di convergenza calcolato su CPU e GPU; dimensionamento di griglia e blocchi a runtime tramite `cudaGetDeviceProperties` e `cudaMemGetInfo`, come richiesto dal requisito di portabilità; granularità adattiva (un thread, un warp o un blocco per riga a seconda della sua lunghezza).

Perché una granularità variabile. La distribuzione delle lunghezze di riga, misurata da `csr_info.c`, è riportata in Tabella 1, e le sue due metà dicono cose opposte. Nei grafi utilizzati, `wiki-Vote` a parte, fra il 31 e l'88% delle righe contiene al più 4 elementi, ma quelle righe valgono appena il 3,5–29% degli archi; le righe oltre i 32 elementi sono al più il 18% e ne raccolgono dal 40 al 68%, con singole righe che arrivano a centinaia di migliaia di predecessori. Fa eccezione `cit-Patents`, che non ha hub: due terzi dei suoi archi stanno in righe da 5 a 32 elementi, e quelle più lunghe ne raccolgono appena il 9%. Queste considerazioni vanno a giustificare la scelta: le righe vengono raggruppate per lunghezza, così che un warp o un blocco riceva righe di dimensione simile e nessun thread resti inattivo ad aspettare gli altri.

Tabella 1: Distribuzione delle lunghezze di riga (predecessori per nodo): quota percentuale di nodi e di archi per classe.

Grafo	0	1–4		5–32		>32		max
	nodi	nodi	archi	nodi	archi	nodi	archi	
wiki-Vote	66,5	3,0	0,5	12,9	14,8	17,6	84,8	457
web-NotreDame	0,0	87,6	29,2	10,1	24,0	2,3	46,8	10 721
web-Stanford	7,2	70,3	17,8	20,6	26,8	1,9	55,4	38 606
web-Google	18,4	56,7	16,4	22,3	43,2	2,6	40,4	6 326
web-BerkStan	9,9	64,2	11,5	22,6	21,5	3,3	67,0	84 208
cit-Patents	13,7	56,5	25,9	29,0	65,0	0,8	9,1	779
wiki-topcats	0,0	58,4	7,4	35,0	24,6	6,6	67,9	238 040
soc-Pokec	6,9	31,4	3,5	43,7	33,4	18,0	63,1	13 733
soc-LiveJournal1	7,4	45,2	6,2	36,7	33,8	10,7	60,0	13 906

2.8 Strategia di verifica

Il programma produce milioni di valori, non ispezionabili a occhio. La correttezza è quindi stabilita ricalcolando il risultato per vie che non condividono codice con l'implementazione sotto esame (`tools/verify_pagerank.py`):

1. PageRank viene ricalcolato su una **matrice densa** $N \times N$, applicando l'iterazione (3) con un solo prodotto matrice-vettore anziché con i due cicli del nucleo di calcolo; il codice è scritto da me;
2. il riferimento denso viene confrontato con **NetworkX**; il codice è di terze parti;
3. si verifica infine che il risultato del **programma C** coincida con il riferimento. Prima del confronto si verificano due condizioni sul risultato stesso: che il programma sia giunto a convergenza e che la somma dei rank sia 1.

Un errore nella conversione da testo a CSR (`tools/snap_to_csr.py`) non sfugge: i risultati dei riferimenti (matrice densa e NetworkX) nascono dall'edge list originale (`.txt`), mentre il programma C calcola dal `.csr`: se i due non corrispondessero, il confronto metterebbe a paragone il PageRank di due grafi diversi e i valori non coinciderebbero.

Poiché la matrice densa richiede N^2 elementi, il punto 1 è possibile solo sul grafo più piccolo: 386 MiB per `wiki-Vote` contro i 5,6 TiB che servirebbero per `web-Google`. È questa la ragione per cui `wiki-Vote` fa parte dell'insieme di test. Sui quattro grafi web il confronto del programma C con NetworkX è l'unico possibile.

Il controllo è quindi svolto su `wiki-Vote` e sui quattro grafi web, e queste istanze vengono ritenute sufficienti per stabilire che il codice è corretto.

Sulle quattro istanze maggiori il confronto con NetworkX non è praticabile. NetworkX rappresenta il grafo con dizionari Python, a circa 500 byte per arco: `soc-LiveJournal1` ne richiederebbe più di 30.

Il controllo viene svolto sia su tutti i valori sia sull'ordine dei primi k nodi (default 100). Quello sull'ordine ha senso solo in testa: più in giù i punteggi si addensano fino a coincidere e l'ordine fra pari dipende solo da come l'ordinamento spezza i pareggi. Uno scambio viene perciò segnalato come errore soltanto se avviene fra valori effettivamente distinti.

Il controllo di convergenza al punto 3 è stato implementato perché il riferimento e il programma ricevono lo stesso tetto di iterazioni, e se lo si abbassa entrambi si fermano allo stesso punto, con valori che coincidono pur essendo lontani dall'essersi stabilizzati. Il confronto avrebbe allora successo su un risultato quantitativamente sbagliato, accettandolo come corretto. Per la stessa ragione anche il riferimento denso viene scartato se non giunge a convergenza.

3 Risultati sperimentali

3.1 Ambienti di prova

Macchina 1	
Sistema operativo	Ubuntu 22.04.5 LTS, kernel Linux 6.8
CPU	Intel Core i5-9300H, 4 core fisici / 8 thread, 2,40–4,10 GHz
Cache	L1d 128 KiB, L2 1 MiB, L3 8 MiB
RAM	16 GiB
GPU	NVIDIA GeForce GTX 1050 Ti, 4 GiB, compute capability 6.1, 6 SM
Compilatore	gcc, OpenMP 4.5; CUDA Toolkit 12.8
Opzioni	-std=c11 -Wall -Wextra -O2
Macchina 2	
Sistema operativo	Ubuntu 20.04.6 LTS, kernel Linux 5.15
CPU	Intel Core i7-6700, 4 core fisici / 8 thread, 3,40–4,00 GHz
Cache	L1d 128 KiB, L2 1 MiB, L3 8 MiB
RAM	32 GiB
GPU	NVIDIA GeForce RTX 2080 Ti, 11 GiB, compute capability 7.5, 68 SM NVIDIA GeForce GTX 1080 Ti, 11 GiB, compute capability 6.1, 28 SM
Compilatore	gcc 9.4, OpenMP 4.5; CUDA Toolkit 11.8
Opzioni	-std=c11 -Wall -Wextra -O2
Macchina 3	
Sistema operativo	Ubuntu 24.04.4 LTS, kernel Linux 6.8
CPU	Intel Xeon W-3323, 12 core fisici / 24 thread, 3,50–3,90 GHz
Cache	L1d 576 KiB, L2 15 MiB, L3 21 MiB
RAM	64 GiB
GPU	NVIDIA GeForce RTX 2080 Ti, 11 GiB, compute capability 7.5, 68 SM NVIDIA GeForce RTX 2080 Ti, 11 GiB, compute capability 7.5, 68 SM
Compilatore	gcc 13.3, OpenMP 4.5; CUDA Toolkit 13.1
Opzioni	-std=c11 -Wall -Wextra -O2

La versione OpenMP è stata misurata sulla Macchina 1 e sulla Macchina 3. La seconda ha il triplo dei core fisici e una L3 di 21 MiB anziché 8.

3.2 Istanze di prova

Sono stati usati nove grafi reali della collezione SNAP [2]: una rete di voti fra utenti di Wikipedia, quattro reti web (tre di pagine di domini universitari e una diffusa da Google), una rete di citazioni fra brevetti, una di collegamenti fra voci di Wikipedia e due reti sociali.

Ogni istanza ha un ruolo. **wiki-Vote** è troppo piccola perché i tempi siano significativi e resta nell'insieme come riferimento di correttezza (Sezione 2.8).

I quattro grafi web, di taglia simile (da 1,5 a 7,6 milioni di archi), formano due coppie che differiscono per la numerazione dei nodi: in **web-NotreDame** e **web-BerkStan** i predecessori di un nodo hanno indici vicini, in **web-Stanford** e **web-Google** sono abbastanza lontani da richiedere quasi a ogni arco una linea di cache nuova (Tabella 6). Così l'effetto della località si osserva su due casi per parte, e non su uno solo.

Le quattro istanze maggiori, da 16,5 a 69 milioni di archi, hanno tutte un vettore **contrib** in doppia precisione più grande della cache L3 della Macchina 1, e due anche di quella della

Tabella 2: Istanze utilizzate.

Grafo	Nodi	Archi	Dangling	max in-deg	CSR
wiki-Vote	7 115	103 689	1 005	457	0,5 MiB
web-NotreDame	325 729	1 497 134	187 788	10 721	9,4 MiB
web-Stanford	281 903	2 312 497	172	38 606	12,0 MiB
web-Google	875 713	5 105 039	136 259	6 326	29,5 MiB
web-BerkStan	685 230	7 600 595	4 744	84 208	36,8 MiB
cit-Patents	3 774 768	16 518 948	1 685 423	779	106,2 MiB
wiki-topcats	1 791 489	28 511 807	0	238 040	129,3 MiB
soc-Pokec	1 632 803	30 622 564	200 110	13 733	135,5 MiB
soc-LiveJournal1	4 847 571	68 993 773	539 119	13 906	318,7 MiB

Macchina 3 (Tabella 6). Ciascuna ha poi una sua particolarità: **cit-Patents** non ha hub (nessun brevetto è citato più di 779 volte) e ha le righe più corte, 4,4 predecessori in media; **wiki-topcats** ha l'hub più estremo, con 238 040 predecessori, e nessun nodo dangling; **soc-Pokec** e **soc-LiveJournal1** hanno la quota più alta di righe lunghe, oltre 32 predecessori per il 18,0 e il 10,7% dei nodi (Tabella 1).

3.3 Correttezza

La Tabella 3 raccoglie i confronti fra le tre implementazioni. Lo scarto è la maggiore differenza in valore assoluto fra i rank corrispondenti, cercata su tutti gli N nodi. I confronti usano la build sequenziale; ripetuti con quella OpenMP danno lo stesso scarto.

Tabella 3: Confronto fra le tre implementazioni.

Confronto	Istanza	Scarto	Esclude
NetworkX contro denso	wiki-Vote	$4,5 \cdot 10^{-12}$	fraintendimenti dell'algoritmo
C contro denso	wiki-Vote	$7,1 \cdot 10^{-14}$	errori nella rappresentazione dei dati
C contro NetworkX	grafi web	$3,6 \cdot 10^{-10}$	errori su grafi grandi

Lo scarto contro NetworkX riportato in tabella è quello di **web-NotreDame**, il più alto dei quattro grafi web; sugli altri tre resta sotto $6,5 \cdot 10^{-11}$. In ogni caso è ben al di sotto della soglia di 10^{-8} usata dallo strumento di verifica.

In tutte le 405 esecuzioni registrate nei **bench.csv** delle Macchine 1 e 3 la somma dei rank si discosta da 1 per non più di $1,4 \cdot 10^{-11}$ in doppia precisione e $2,7 \cdot 10^{-8}$ in singola: la massa dei nodi dangling non si disperde.

3.4 Misura dei tempi

Il tempo riportato per ogni esecuzione è quello del solo ciclo delle iterazioni: l'orologio si legge appena prima della prima iterazione e appena dopo l'ultima, con `clock_gettime(CLOCK_MONOTONIC)` (la funzione `wall_seconds` nel codice). È tempo reale trascorso, non tempo di CPU: con OpenMP quest'ultimo sommerebbe il lavoro di tutti i thread e non mostrerebbe alcuno speed-up. Restano fuori dalla misura le operazioni fatte una volta sola: la lettura del file `.csr` e, nella versione ibrida, il trasferimento del grafo verso la GPU e quello dei rank finali verso l'host.

Si è preso in considerazione di misurare i tempi con gli eventi (`cudaEventRecord`, `cudaEventElapsedTime`) e con il profiler (`nvprof`, `nsys`), ma per i tempi complessivi si

è preferito un orologio dell'host, per due ragioni: la prima è che i tempi delle tre versioni vanno confrontati fra loro, quindi devono venire dallo stesso orologio: la build sequenziale non ha né CUDA né OpenMP, perciò non dispone né degli eventi né di `omp_get_wtime`, mentre `clock_gettime` è disponibile ovunque. La seconda è che gli eventi misurano ciò che accade negli stream della GPU, mentre nella versione ibrida una parte del lavoro la svolge la CPU (Sezione 2.7): solo un orologio dell'host vede le due parti insieme.

La misura resta corretta anche se i kernel vengono lanciati in modo asincrono, perché ogni iterazione si chiude con `cudaStreamSynchronize`: quando l'orologio viene letto per l'ultima volta, la GPU ha davvero finito. Lo conferma il confronto con il profiler: con tutto il lavoro sulla GPU, il tempo così misurato coincide entro 0,06 ms con l'intervallo che `nsys` registra fra la prima e l'ultima operazione della GPU.

Il profiler resta lo strumento per il dettaglio: `nsys` registra inizio e fine di ogni kernel e di ogni trasferimento, ed è da lì che vengono le durate delle singole fasi della versione ibrida. Gli eventi CUDA compaiono nel codice solo per sincronizzare i due stream di quella versione, e sono creati con `cudaEventDisableTiming`, cioè senza registrare il tempo.

3.5 Scalabilità della versione OpenMP

Ogni configurazione è stata eseguita tre volte; si riporta il minimo, visto che l'attività di sistema può rallentare un'esecuzione.

Con p thread, lo speed-up e l'efficienza parallela sono definiti come

$$S(p) = \frac{T_{\text{seq}}}{T(p)}, \quad E(p) = \frac{S(p)}{p}, \quad (4)$$

dove T_{seq} è il tempo della build sequenziale (compilata senza `-fopenmp`) e $T(p)$ quello della build OpenMP a p thread.

Tabella 4: Tempi di esecuzione in secondi sulla Macchina 1 (4 core fisici, 8 thread). Lo speed-up dell'ultima colonna è calcolato tra la configurazione in doppia precisione più veloce e quella sequenziale.

Grafo	seq	1 thr	2 thr	4 thr	8 thr	float 8	speed-up
web-NotreDame	0,150	0,156	0,087	0,054	0,049	0,048	3,04×
web-Stanford	0,325	0,319	0,165	0,099	0,092	0,096	3,55×
web-Google	1,151	1,177	0,645	0,377	0,361	0,259	3,19×
web-BerkStan	0,658	0,665	0,355	0,216	0,192	0,171	3,43×
cit-Patents	1,199	1,225	0,729	0,481	0,466	0,284	2,57×
wiki-topcats	2,397	2,424	1,342	0,828	0,765	0,517	3,13×
soc-Pokec	4,098	4,115	2,293	1,401	1,400	0,907	2,93×
soc-LiveJournal1	11,198	11,461	6,575	4,449	4,229	3,234	2,65×

Nella Figura 2 le otto curve della Macchina 1 si appiattiscono fra 4 e 8 thread, e quasi tutte si allontanano dall'andamento lineare già a 2: fa eccezione **web-Stanford**, che a 2 thread ha ancora un'efficienza del 98 %. L'efficienza (Figura 3) è dell'82–98 % a 2 thread, del 62–82 % a 4 e del 32–44 % a 8.

Il calcolo è memory-bound. Passando da 4 a 8 thread il tempo, anziché dimezzarsi, scende al più dell'11 % (**web-BerkStan**), e su **soc-Pokec** resta invariato. Il processore della Macchina 1 possiede 4 core fisici presentati come 8 thread logici; i due thread che stanno sullo stesso core




Figura 2: Scalabilità della versione OpenMP, un pannello per grafo e una curva per macchina, su assi logaritmici. Il riferimento per lo speed-up è la build sequenziale di ciascuna macchina. La linea tratteggiata diagonale indica lo speed-up lineare ideale $S(p) = p$, le linee continue quelli misurati, con il massimo raggiunto in etichetta; le linee punteggiate verticali segnano i core fisici di ciascuna macchina, 4 e 12. Figura generata da `tools/plot_results.py` a partire da `results/machine1/bench.csv` e `results/machine3/bench.csv`.




Figura 3: Efficienza parallela della versione OpenMP, un pannello per grafo e una curva per macchina. La linea tratteggiata indica l'efficienza ideale del 100%, le linee continue quelle misurate, con in etichetta il valore al massimo numero di thread; le linee punteggiate verticali segnano i core fisici, come nella Figura 2. Figura generata da `tools/plot_results.py` a partire da `results/machine1/bench.csv` e `results/machine3/bench.csv`.

Tabella 5: Tempi di esecuzione in secondi sulla Macchina 3 (12 core fisici, 24 thread). Lo speed-up è calcolato come nella Tabella 4.

Grafo	seq	thread							float 24	speed-up
		1	2	4	8	12	16	24		
web-NotreDame	0,142	0,144	0,085	0,045	0,025	0,018	0,016	0,014	0,014	10,51×
web-Stanford	0,334	0,338	0,172	0,090	0,048	0,035	0,032	0,028	0,021	11,88×
web-Google	1,081	1,119	0,573	0,292	0,158	0,117	0,108	0,099	0,079	10,90×
web-BerkStan	0,683	0,695	0,421	0,215	0,126	0,093	0,085	0,083	0,063	8,20×
cit-Patents	0,979	0,988	0,538	0,288	0,176	0,140	0,137	0,128	0,096	7,68×
wiki-topcats	1,936	1,775	0,998	0,525	0,310	0,239	0,236	0,227	0,183	8,54×
soc-Pokec	2,728	2,737	1,491	0,789	0,447	0,351	0,332	0,320	0,262	8,51×
soc-LiveJournal1	8,081	8,296	4,554	2,489	1,540	1,259	1,236	1,178	0,810	6,86×

condividono anche cache e unità di accesso alla memoria. Poiché ogni thread passa la maggior parte del tempo in attesa della lettura `contrib[col_idx[j]]`, i thread aggiuntivi raddoppiano le richieste, non le unità che le servono. Il *simultaneous multithreading* (SMT) rende quando un thread calcola mentre l'altro aspetta, ma qui aspettano entrambi.

Con più core fisici. Se il limite sono le unità di accesso alla memoria di ciascun core, a spostarlo deve essere il numero di core fisici, non quello dei thread. La Macchina 3, con 12 core fisici e 24 thread logici, lo conferma (Tabella 5 e Figura 2). Finché ogni thread nuovo trova un core libero lo speed-up continua a crescere: a 8 thread l'efficienza è ancora del 66–86 %, contro il 32–44 % della Macchina 1, e a 12 del 54–79 %, poco sotto il 62–82 % che la Macchina 1 ha a 4, quando anche lì ogni core ha il suo thread. Oltre i 12 thread osserviamo lo stesso fenomeno della Macchina 1, con lo speed-up che cresce più lentamente e l'efficienza che cala più rapidamente. La curva si piega fortemente, dunque, in corrispondenza della fine dei core fisici.

Anche per la Macchina 3 la resa di SMT segue la memoria. Il guadagno da 12 a 24 thread è massimo nei grafi minori, come **web-NotreDame** e **web-Stanford**, che sono gli unici due grafi i cui dati — il CSR e i tre vettori `cur`, `nxt` e `contrib` — stanno per intero nei 21 MiB della L3.³ In sostanza, il thread gemello rende quando l'attesa è breve, come quando i dati arrivano dalla cache, e poco quando arrivano dalla memoria.

web-Google impiega più tempo di web-BerkStan. A 4 thread e sulla Macchina 1 **web-Google** impiega 0,377 s contro i 0,216 s di **web-BerkStan**, il 74 % in più, e non è una questione di iterazioni perché ne esegue di meno (62 contro 64). Non è nemmeno una questione di lavoro svolto, perché **web-BerkStan** ha il 49 % di archi in più: a parità di arco **web-Google** costa 1,19 ns⁴ contro 0,44 di **web-BerkStan**, più di due volte e mezzo tanto.

Ogni riga — i predecessori di un nodo — porta un costo fisso (leggere i due estremi in `row_ptr`, scrivere il rank nuovo e aggiornare l'errore), e **web-Google** ha il 28 % di nodi in più. Quel 28 % è però un tetto di miglioramento ideale: lo si raggiungerebbe solo se gli archi fossero gratis, mentre il divario osservato è il 74 %. Non lo spiega neppure la concentrazione nelle righe lunghe: **soc-LiveJournal1** ha il 60 % degli archi oltre i 32 predecessori, quasi quanto il 67 % di **web-BerkStan** (Tabella 1), eppure per arco costa 1,26 ns, poco più di **web-Google**.

La differenza sta in quanto distano un indice e il successivo, visto che il ciclo recupera i contributi dei predecessori `contrib[col_idx[j]]` in ordine sparso, perché i valori di `col_idx` non sono

³**web-NotreDame**: 9,4 MiB di CSR più tre vettori da 2,5 MiB, 16,9 MiB in tutto; **web-Stanford**: 12,0 MiB più tre vettori da 2,2 MiB, circa 18,5 MiB.

⁴0,377 s / 62 iterazioni = 0,00608 s; 0,00608 s / 5105039 archi = 1,19 ns per arco.

sequenziali. In **web-BerkStan** i predecessori di un nodo hanno indici quasi consecutivi, infatti il salto mediano fra due indici della stessa riga è 1, una conseguenza di come sono stati raccolti e salvati i dati: una sola linea di cache da 64 byte porta con sé 8 contributi consecutivi, e ne bastano poche per servire un'intera riga: in media una linea ogni 16 archi, 0,06 linee per arco (Tabella 6), cosicché questa raccolta di valori da posizioni sparse — il *gather* — si riduce a una lettura quasi sequenziale. In **web-Google** gli indici sono sparsi su tutto l'array, con un salto mediano di quasi 17000 posizioni, e quasi ogni arco pretende una linea di cache nuova (0,99 linee per arco)⁵: 64 byte trasferiti per usarne solo 8. Su una iterazione fanno 309 MiB di linee di cache richieste contro 29. Le letture sequenziali vanno nel verso opposto: `col_idx`, `row_ptr` e i vettori di rank (`nxt` e `cur`) fanno 53 MiB su **web-BerkStan** contro 50 su **web-Google**. La Tabella 7 mostra la riga del nodo 1 nei due grafi.

Le linee richieste non costano tutte uguali: `contrib` occupa 6,7 MiB su **web-Google** e 5,2 MiB su **web-BerkStan**, abbastanza poco perché una parte degli accessi sparsi resti servita dalla cache invece di arrivare in memoria. L'altra coppia di grafi web lo mostra dal lato opposto: **web-Stanford** ha indici sparsi quasi quanto **web-Google**, 0,91 linee di cache per arco contro 0,99, ma il suo `contrib` di 2,2 MiB sta per intero in cache con ampio margine, e il divario con **web-NotreDame**, locale come **web-BerkStan**, si riduce a 0,68 contro 0,62 ns per arco. Che **web-NotreDame** costi per arco più di **web-BerkStan** dipende invece dalla lunghezza delle righe, 4,6 predecessori in media contro 11,1: il costo fisso di ogni riga si divide su meno archi.

La cache manca del tutto alle quattro istanze maggiori, i cui `contrib`, da 12,5 a 37 MiB, nella L3 da 8 MiB non entrano: la gran parte delle linee che il *gather* richiede va cercata in memoria, e il costo per arco dipende sia dalla località sia da quanta parte di `contrib` la cache riesce ancora a trattenere. **wiki-topcats**, la più locale delle quattro (0,42 linee per arco), costa 0,79 ns per arco; **cit-Patents**, la meno locale (0,96) e con le righe più corte, 1,94 ns, il valore più alto di tutti. **soc-Pokec** ha indici più sparsi di **soc-LiveJournal1** (0,80 linee per arco contro 0,52) ma un `contrib` tre volte più piccolo, e costa meno (1,04 contro 1,26 ns); **soc-LiveJournal1**, a sua volta, nonostante una località migliore di quella di **web-Google**, paga per arco un po' di più.

La Macchina 3 conferma questa lettura dal lato dell'hardware (colonne M1 e M3 della Tabella 6). Il suo core non è più veloce: da sequenziale, sui quattro grafi web, le due CPU si equivalgono entro il 6%. Ha però una L3 di 21 MiB anziché 8, e a 4 thread il suo vantaggio è modesto sui quattro grafi web, il cui `contrib` sta già nella L3 della Macchina 1, e forte sulle quattro istanze maggiori, il cui `contrib` non ci sta. Ciò che la Macchina 3 ha in più sta dunque nella gerarchia di memoria, e rende proprio dove la Macchina 1 aspetta la RAM.

3.6 Confronto fra le varianti float e double

Sulla Macchina 1, a 8 thread e a parità di numero di iterazioni, la variante in singola precisione riduce il tempo fra il 24 e il 39% sulle cinque istanze in cui `contrib`, in doppia precisione, occupa quasi tutta la L3 o la supera: **web-Google**, **cit-Patents**, **wiki-topcats**, **soc-Pokec** e **soc-LiveJournal1**. Sugli altri tre grafi web, dove `contrib` sta in cache o viene letto quasi in sequenza, il guadagno scende all'11% su **web-BerkStan** e sparisce sugli altri due, dove la differenza (+3% su **web-NotreDame**, -4% su **web-Stanford**) può essere attribuita al rumore di misura. Il guadagno si concentra dunque dove il *gather* va in memoria, ed è coerente con il dimezzamento dei byte trasferiti per ogni rank: un'ulteriore conferma indiretta della natura memory-bound del calcolo.

Sulla Macchina 3, a 24 thread, il guadagno si allarga a sette grafi su otto, dal 18 al 31%, e comprende **web-Stanford** e **web-BerkStan**, che sulla Macchina 1 guadagnavano poco o nulla.

⁵Linee di cache distinte contate da `tools/locality_stats.py`; 5054775 linee / 5105039 archi = 0,99 linee per arco; 5054775 linee × 64 byte = 309 MiB per iterazione.

Tabella 6: Località della lettura sparsa su `contrib`. Il salto è la mediana di `col_idx[j+1] - col_idx[j]` all'interno di una riga; le linee di cache distinte sono contate su blocchi di 256 righe, che è l'unità di schedulazione del ciclo, e divise per il numero di archi danno le linee per arco; il gather per iterazione è il volume che ne risulta. Misure prodotte da `tools/locality_stats.py` dai file `.csr`; i tempi per arco vengono dai 4 thread della Tabella 4 per la Macchina 1 (M1) e della Tabella 5 per la Macchina 3 (M3).

Grafo	salto	linee	gather	contrib	ns per arco	
	mediano	per arco	per iter.		M1	M3
web-NotreDame	1	0,07	7 MiB	2,5 MiB	0,62	0,52
web-Stanford	1 080	0,91	129 MiB	2,2 MiB	0,68	0,62
web-Google	16 836	0,99	309 MiB	6,7 MiB	1,19	0,92
web-BerkStan	1	0,06	29 MiB	5,2 MiB	0,44	0,44
cit-Patents	60 903	0,96	973 MiB	28,8 MiB	1,94	1,16
wiki-topcats	59	0,42	725 MiB	13,7 MiB	0,79	0,50
soc-Pokec	10 319	0,80	1 501 MiB	12,5 MiB	1,04	0,59
soc-LiveJournal1	3 104	0,52	2 172 MiB	37,0 MiB	1,26	0,71

Tabella 7: I primi cinque predecessori del nodo 1 come finiscono in `col_idx`, con la distanza fra un indice e il successivo.

Grafo	Primi cinque indici in <code>col_idx</code>				
web-Google	193 140	262 338	525 606	541 488	713 368
<i>salti</i>		69 198	263 268	15 882	171 880
web-BerkStan	2	6	15	17	19
<i>salti</i>		4	9	2	2

Resta nullo solo su **web-NotreDame** (-2%), il più piccolo degli otto grafi e quello con il gather per iterazione più leggero.

Il limite della singola precisione si manifesta sulla soglia di convergenza: su **web-Google** l'errore L_1 non scende sotto $\approx 5 \cdot 10^{-9}$, per cui una tolleranza di 10^{-9} non viene mai raggiunta, mentre la doppia precisione la raggiunge in 104 iterazioni. Alla tolleranza utilizzata negli esperimenti (10^{-6}) entrambe convergono nello stesso numero di iterazioni.

3.7 Risultati della versione ibrida

[DA COMPLETARE] Sezione da scrivere: tempi della versione CUDA e ibrida, confronto con OpenMP, occupancy, effetto della granularità adattiva, effetto della sovrapposizione fra trasferimenti e calcolo.

4 Valutazioni e osservazioni

4.1 Punti di forza

- **Assenza di sincronizzazione nel nucleo di calcolo.** La formulazione *pull*, con il grafo memorizzato trasposto, elimina alla radice le scritture concorrenti, e si trasferisce invariata alla versione CUDA.
- **Il CSR è adattato al problema.** Il valore di un non nullo dipende solo dalla colonna, non dal singolo arco: il formato generico obbligherebbe a ripetere lo stesso $1/\text{outdeg}(u)$

una volta per arco uscente di u , mentre `out_deg[N]` lo registra una volta sola. E' un'informazione duplicata che non viene scritta.

- **Il vettore contrib riduce gli accessi sparsi.** Senza di esso il ciclo di accumulo dovrebbe leggere, per ogni arco, `cur[u]` e `out_deg[u]`: due array distinti, quindi due accessi imprevedibili invece di uno. Precalcolare il quoziente porta le divisioni da M a N , ma soprattutto lascia una lettura sola per arco.
- **Verifica indipendente e collaudata.** Tre implementazioni concordano, e lo strumento di verifica è stato validato con un'iniezione di guasto.

4.2 Punti deboli e limiti

- **Il convertitore non scala oltre le istanze usate.** Il convertitore Python mantiene l'intera edge list in memoria: se in futuro si volessero trattare grafi sensibilmente più grandi, andrebbe ripensato.
- **Formato binario non standard.** Il formato `.csr` è specifico del progetto: è velocissimo da caricare e tiene il programma C libero da un parser, ma non è ispezionabile con strumenti esterni.
- **Dimensione della porzione dinamica non ottimizzata.** Il valore 256 di `schedule(dynamic, 256)` non è stato oggetto di una ricerca sistematica.

4.3 Possibili miglioramenti

- **Ricerca su politica di scheduling e dimensione del blocco.** Il parametro non governa solo il bilanciamento del carico: blocchi più ampi danno a un thread più righe consecutive, quindi più riuso delle linee già in cache. L'ottimo è un compromesso fra le due cose e dipende dal grafo; varrebbe la pena cercarlo, confrontando anche politiche come `guided`.
- **Soglie della granularità adattiva.** Nella versione ibrida la GPU dà un thread alle righe fino a 16 predecessori, un warp a quelle fino a 256 e un blocco alle più lunghe (opzione `-b`). Queste due soglie sono state fissate dopo poche prove, senza un'analisi approfondita, e quelle migliori dipendono verosimilmente dal grafo e dalla GPU: andrebbero cercate in modo sistematico, misurando il gather al variare delle due soglie. Le soglie 4 e 32 della Tabella 1 servono invece solo a illustrare l'idea.
- **Bilanciamento automatico della quota.** Nella versione ibrida la quota di archi assegnata alla CPU è un parametro (`-s`), e la migliore è quella con cui CPU e GPU finiscono il proprio lavoro insieme: dipende quindi dal grafo e dal rapporto fra la velocità della CPU e quella della GPU della macchina. Il programma potrebbe trovarla da solo nelle prime iterazioni: se a fine iterazione la CPU ha aspettato la GPU, le cede altre righe; se invece è la GPU ad aver aspettato, gliene toglie. Sarebbe l'estensione naturale del requisito di portabilità alla ripartizione del lavoro, che oggi si sceglie a mano.

[DA COMPLETARE] Aggiungere la valutazione personale complessiva una volta completata la fase CUDA.

4.4 Codice sorgente e guida all'uso

La repository è disponibile all'indirizzo

<https://github.com/EmanueleCecchia/pagerank-openmp-cuda>

Il `README.md` fa da guida all'uso e contiene le istruzioni per riscaricare i dataset, che non sono versionati per ragioni di dimensione.

Riferimenti bibliografici

- [1] L. Page, S. Brin, R. Motwani, T. Winograd, *The PageRank Citation Ranking: Bringing Order to the Web*, Stanford InfoLab, 1999.
- [2] J. Leskovec, A. Krevl, *SNAP Datasets: Stanford Large Network Dataset Collection*, <https://snap.stanford.edu/data>, 2014.