

PageRank su Architetture Ibride

Parallelizzazione con OpenMP e CUDA

Emanuele Cecchia

Corso di Programmazione su Architetture Parallele

A.A. 2025–26 — Prof. Andrea Formisano

17 settembre 2026

Abstract

Il progetto implementa e analizza l'algoritmo PageRank su architetture parallele, confrontando tre versioni: una sequenziale, che fa da riferimento per ogni misura di speed-up, una puramente multicore basata su OpenMP e una ibrida che distribuisce il carico fra CPU e GPU tramite CUDA. Sequenziale e OpenMP condividono lo stesso file sorgente e differiscono solo per le opzioni di compilazione, così che il riferimento non possa divergere dal codice parallelo né essere falsato dai costi di gestione dei thread. Il grafo è memorizzato trasposto in formato CSR, scelta che rende il nucleo di calcolo privo di scritture concorrenti e quindi parallelizzabile senza sincronizzazione. La correttezza è verificata contro tre implementazioni indipendenti. Le misure sulla versione OpenMP mostrano uno speed-up di $2,4\text{--}2,9\times$ su 4 core fisici e, soprattutto, una saturazione oltre i 4 thread che identifica il calcolo come *memory-bound*: è questo il dato che motiva quantitativamente il passaggio alla GPU.

[DA COMPLETARE] Aggiornare l'abstract con i risultati CUDA una volta completata la fase ibrida.

Indice

1	Descrizione del problema affrontato	3
1.1	Il problema	3
1.2	Damping factor e Dangling Mass	3
1.3	Forma matriciale	4
1.4	Algoritmo	4
1.5	Necessità della parallelizzazione	5
2	Metodologia adottata per la soluzione	6
2.1	Struttura del codice	6
2.2	Rappresentazione dei dati: CSR	6
2.3	Formato binario e pre-elaborazione	8
2.4	Precisione: <code>float</code> contro <code>double</code>	10
2.5	Validazione del file in ingresso	10
2.6	Implementazione sequenziale e OpenMP	11
2.7	Implementazione ibrida OpenMP + CUDA	11
2.8	Strategia di verifica	12

3	Risultati sperimentali	13
3.1	Ambiente di prova	13
3.2	Istanze di prova	13
3.3	Correttezza	13
3.4	Scalabilità della versione OpenMP	14
3.5	Confronto fra le varianti <code>float</code> e <code>double</code>	15
3.6	Risultati della versione ibrida	15
4	Valutazioni e osservazioni	15
4.1	Punti di forza	15
4.2	Punti deboli e limiti	15
4.3	Possibili miglioramenti	16
5	Guida all'uso e riproducibilità	16
5.1	Requisiti	16
5.2	Compilazione	16
5.3	Preparazione dei dati	16
5.4	Esecuzione	17
5.5	Verifica della correttezza	17
5.6	Riproduzione degli esperimenti	17
5.7	Codice sorgente	17

1 Descrizione del problema affrontato

1.1 Il problema

PageRank assegna a ogni nodo di un grafo orientato un punteggio di importanza, definito ricorsivamente: un nodo è importante se nodi importanti puntano ad esso. Nato per ordinare le pagine web in base alla struttura dei collegamenti ipertestuali [1], viene oggi applicato anche a reti sociali, reti di citazioni e reti biologiche.

La definizione è ricorsiva e si risolve iterativamente: si parte da una distribuzione uniforme e la si raffina finché non cambia più — in pratica, finché la variazione non scende sotto una soglia prefissata, oppure fino a un numero massimo di iterazioni. Equivale al modello del *navigatore casuale*, che segue collegamenti scelti a caso: il PageRank è la frazione di tempo che costui trascorre su ciascuna pagina. Ne discendono due proprietà della formula — il totale vale 1, perché il navigatore è sempre da qualche parte, e un collegamento pesa tanto meno quanti più ne partono dalla stessa pagina.

Formalmente, dato un grafo orientato $G = (V, E)$ con $N = |V|$,

$$\text{PR}_{t+1}(v) = \frac{1-d}{N} + d \left(\sum_{u: u \rightarrow v} \frac{\text{PR}_t(u)}{\text{outdeg}(u)} + \frac{\text{dangling}_t}{N} \right) \quad (1)$$

dove i simboli hanno il seguente significato:

$\text{PR}_t(v)$	<i>PageRank</i> : punteggio del nodo v alla t -esima iterazione
$\text{outdeg}(u)$	numero di archi uscenti da u
d	<i>damping factor</i> , convenzionalmente 0,85
dangling_t	<i>dangling mass</i> : punteggio complessivo dei nodi senza archi uscenti $\text{dangling}_t = \sum_{u: \text{outdeg}(u)=0} \text{PR}_t(u)$
N	numero di nodi

1.2 Damping factor e Dangling Mass

Il termine $(1-d)/N$: un gruppo di pagine che si citano solo fra loro assorbirebbe, iterazione dopo iterazione, tutto il punteggio del grafo, perché i collegamenti vi entrano e nessuno ne esce. Con probabilità $1-d$ il navigatore abbandona i collegamenti e salta su una pagina qualsiasi: questo impedisce l'accumulo e rende ogni nodo raggiungibile da ogni altro. È anche l'unica via d'uscita da un nodo senza archi uscenti, dove con $d=1$ il navigatore resterebbe intrappolato per sempre.

Il termine $\text{dangling}_t/N$: un nodo senza archi uscenti non ha modo di ridistribuire il proprio rank. Il salto casuale lo libera con probabilità $1-d$, ma la quota d restante cercherebbe un collegamento che non esiste: è questa che il termine raccoglie e ridistribuisce. Ignorandolo, ad ogni iterazione una frazione della massa totale sparirebbe e il vettore cesserebbe di essere una distribuzione di probabilità. Nei dataset utilizzati questo non è un caso limite: il 15,6% dei nodi di **web-Google** e l'11,1% di **soc-LiveJournal1** sono *dangling* (Tabella 2). La conseguenza pratica è che $\sum_v \text{PR}(v) = 1$ costituisce un test di correttezza.

Con entrambi i termini l'iterazione descrive una catena di Markov sui nodi del grafo: da ogni nodo — cicli chiusi e vicoli ciechi compresi — si può sempre raggiungere qualunque altro. Questo ci garantisce un'unica distribuzione stazionaria.

1.3 Forma matriciale

La stessa iterazione si scrive in forma vettoriale. Sia $\mathbf{MT} \in \mathbb{R}^{N \times N}$ la *matrice di transizione* definita da

$$\mathbf{MT}_{vu} = \begin{cases} 1/\text{outdeg}(u) & \text{se esiste l'arco } u \rightarrow v, \\ 0 & \text{altrimenti,} \end{cases} \quad (2)$$

e sia $\mathbf{1}$ il vettore di tutti uni. Detto $\mathbf{PR}_t$ il vettore dei punteggi ($\text{PR}(1), \dots, \text{PR}(N)$), l'iterazione (1) diventa

$$\mathbf{PR}_{t+1} = \frac{1-d}{N} \mathbf{1} + d \left(\mathbf{MT} \mathbf{PR}_t + \frac{\text{dangling}_t}{N} \mathbf{1} \right), \quad \text{dangling}_t = \mathbf{w}^\top \mathbf{PR}_t \quad (3)$$

dove $\mathbf{w}$ è il vettore indicatore dei nodi dangling ($w_u = 1$ se $\text{outdeg}(u) = 0$, altrimenti 0).

Il prodotto $\mathbf{MT} \mathbf{PR}_t$ che compare nella (3) è una moltiplicazione matrice-sparsa per vettore (SpMV, Sparse Matrix-Vector Multiplication): una matrice sparsa moltiplica un vettore denso e ne produce uno nuovo, sempre denso, nella forma generica $\mathbf{y} = \mathbf{Ax}$. È questa l'operazione che il progetto parallelizza. Per non pagare gli zeri né in spazio né in tempo si memorizzano i soli elementi non nulli di $\mathbf{MT}$, usando formati come CSR (Compressed Sparse Row), che vedremo nella Sezione 2.2.

1.4 Algoritmo

Algorithm 1 PageRank per iterazione di potenza (formulazione *pull*)

```

1:  $\text{PR}[v] \leftarrow 1/N$  per ogni  $v \in V$ 
2: repeat
3:    $\text{dangling} \leftarrow 0$ 
4:   for all  $u \in V$  do
5:     if  $\text{outdeg}[u] = 0$  then
6:        $\text{contrib}[u] \leftarrow 0$ ;  $\text{dangling} \leftarrow \text{dangling} + \text{PR}[u]$ 
7:     else
8:        $\text{contrib}[u] \leftarrow \text{PR}[u]/\text{outdeg}[u]$ 
9:     end if
10:  end for
11:   $\text{base} \leftarrow (1-d)/N + d \cdot \text{dangling}/N$ 
12:  for all  $v \in V$  do
13:     $\text{PR}'[v] \leftarrow \text{base} + d \sum_{u \rightarrow v} \text{contrib}[u]$ 
14:  end for
15:   $\varepsilon \leftarrow \sum_v |\text{PR}'[v] - \text{PR}[v]|$ 
16:  scambia  $\text{PR}$  e  $\text{PR}'$ 
17: until  $\varepsilon < \text{tolleranza}$ 

```

N, d	numero di nodi e damping factor: scalari, costanti per tutta l'esecuzione
$PR[v]$	punteggio corrente del nodo v ; PR è un vettore di N componenti, una per nodo
$PR'[v]$	punteggio di v calcolato nell'iterazione in corso; vettore di appoggio, della stessa forma di PR
$contrib[u]$	contributo che u manda lungo ciascuno dei suoi archi uscenti; vettore di N componenti, ricalcolato ad ogni iterazione
$outdeg[u]$	numero di archi uscenti da u ; vettore di N componenti, proprietà fissa del grafo
$dangling$	<i>dangling mass</i> : scalare, punteggio complessivo dei nodi senza archi uscenti
$base$	scalare, quota di punteggio che spetta a ogni nodo indipendentemente dagli archi
ϵ	scalare, variazione complessiva fra un'iterazione e la successiva

Ogni iterazione ricostruisce il vettore dei punteggi a partire da quello precedente, con due passaggi sui nodi. Nel primo ogni nodo è visto come sorgente: si calcola quanto manda lungo ciascun arco uscente e si raccoglie al tempo stesso la *dangling mass*. Nel secondo ogni nodo è visto come destinazione: si sommano i contributi che arrivano dai suoi predecessori. Si ripete finché la variazione complessiva non scende sotto la tolleranza. Il ciclo è il *metodo delle potenze*: si rimoltiplica il vettore finché non si stabilizza, e non serve normalizzarlo a ogni passo perché l'iterazione conserva da sé la somma a 1. *Pull* indica invece che ogni nodo legge dai predecessori anziché scrivere nei successori, scelta motivata nella Sezione 2.2.

Esplicitando *base*, il calcolo di $PR'[v]$ è esattamente l'iterazione (1):

$$PR'[v] = \underbrace{\frac{1-d}{N} + d \frac{dangling}{N}}_{base} + d \sum_{u: u \rightarrow v} contrib[u]$$

dove $contrib[u] = PR[u]/outdeg[u]$ per i nodi con archi uscenti, e $contrib[u] = 0$ per i *dangling*, il cui punteggio confluisce invece in *dangling*.

Il calcolo di $contrib[u]$ — il primo ciclo, quello dei *contributi* — è separato dal secondo, quello di *accumulo*, per una ragione di costo: eseguito così richiede N divisioni per iterazione anziché $M = |E|$, e nei grafi considerati $M \gg N$ (su **soc-LiveJournal1**, 69 milioni contro 4,8 milioni). La divisione è fra le operazioni aritmetiche più lente, quindi il risparmio è reale.

1.5 Necessità della parallelizzazione

La difficoltà del problema è interamente di scala. La matrice **MT** della Sezione 1.3 è *sparsa*: delle sue N^2 celle solo M sono diverse da zero, e nei grafi reali $M \ll N^2$. Rappresentarla come matrice densa $N \times N$ — una cella per ogni coppia (v, u) — richiederebbe una memoria quadratica in N e occupata quasi per intero da zeri, oltre a N^2 moltiplicazioni per iterazione anziché M . Si adotta perciò una rappresentazione *sparsa*, che conservi i soli elementi non nulli — il formato **CSR** della Sezione 2.2. Restano comunque M archi da percorrere a ogni iterazione, e le iterazioni si susseguono fino a convergenza: questo rende necessario distribuire il calcolo su più unità di elaborazione.

2 Metodologia adottata per la soluzione

2.1 Struttura del codice

Il progetto si compone di sette moduli, dei quali due soli formano la parte misurata: `src/pagerank.c`, che contiene il nucleo di calcolo, e `src/csr.c`, che porta il grafo in memoria. Gli altri preparano i dati, guidano l'esecuzione o servono a controllare i risultati.

Modulo	Ruolo
<code>tools/snap_to_csr.py</code>	conversione SNAP $\rightarrow$ CSR binario
<code>src/csr.c</code> , <code>csr.h</code>	caricamento e validazione
<code>src/pagerank.c</code> , <code>.h</code>	nucleo di calcolo
<code>src/main.c</code>	programma principale, output, log dei tempi
<code>src/csr_info.c</code>	statistiche di un grafo convertito
<code>tools/verify_pagerank.py</code>	verifica indipendente
<code>tools/run_benchmarks.sh</code>	misure su tutte le configurazioni

2.2 Rappresentazione dei dati: CSR

Per rappresentare i soli elementi non nulli della matrice **MT**, il formato **CSR** non usa una matrice bidimensionale $N \times N$ ma tre array monodimensionali:

- `col_idx[M]`: gli indici di colonna dei non nulli, letti riga per riga;
- `row_ptr[N+1]`: `row_ptr[v]` è la posizione, dentro `col_idx`, in cui comincia la riga v ;
- `out_deg[N]`: il grado uscente di ogni nodo, cioè il denominatore $\text{outdeg}(u)$ della (1).

La Figura 1 segue la costruzione su un grafo di cinque nodi e otto archi, dal grafo alla matrice agli array.

Tutto ruota attorno a `row_ptr`: gli elementi della riga v sono `col_idx[row_ptr[v] ... row_ptr[v+1]-1]`, e la lunghezza della riga è la differenza fra due offset consecutivi, che quindi non va memorizzata a parte. Nell'esempio della figura la riga 2 comincia in posizione `row_ptr[2] = 4` e finisce prima di `row_ptr[3] = 7`: i predecessori del nodo 2 sono dunque `col_idx[4]`, `col_idx[5]` e `col_idx[6]`, cioè i nodi 0, 1 e 4 — come si può constatare nel grafo. Gli offset sono $N+1$ e non N proprio per questo motivo: la sentinella `row_ptr[N] = M` fa sì che l'ultima riga si tratti come tutte le altre.

Perché manca l'array dei valori. In un CSR generico il terzo array è `val[M]`, con il valore di ogni elemento non nullo; qui al suo posto c'è `out_deg[N]`. Il motivo si legge nella Figura 1(b): tutti i non nulli della colonna u valgono $1/\text{outdeg}(u)$, così che il valore dipenda dalla sola colonna e sia ricavabile da `out_deg`. Ricavarlo a ogni accesso costerebbe però una divisione per arco: dentro `col_idx` ogni nodo u compare tante volte quanti sono i suoi archi uscenti, e ognuna rifarebbe la stessa divisione. Nell'esempio della Figura 1 il nodo 1 compare tre volte, una per ciascuno dei suoi tre archi uscenti, e il quoziente $\text{PR}(1)/3$ verrebbe ricalcolato identico tutte e tre le volte, perché né $\text{PR}(1)$ né $\text{outdeg}(1)$ cambiano durante l'iterazione. Il vettore `contrib` dell'Algoritmo 1 esegue invece la divisione una volta per nodo, in un passaggio separato che precede quello sui predecessori: a quest'ultimo resta solo da leggere `contrib[col_idx[j]]` e sommarlo, senza divisioni e senza valori da recuperare. Anche in memoria il guadagno viene dallo stesso passaggio da M a N , con $N \ll M$: su `soc-LiveJournal1` un `val[M]` in doppia precisione occuperebbe $8 \times M$ byte, cioè circa 526 MiB, mentre a `out_deg` bastano $4 \times N$ byte, circa 18,5 MiB: quasi trenta volte meno.



Figura 1: Costruzione del CSR del grafo trasposto, su un esempio con $N = 5$ nodi e $M = 8$ archi. In (b) la riga v della matrice $\mathbf{MT}$ raccoglie i *predecessori* di v , e ogni colonna u ha il valore costante $1/\text{outdeg}(u)$. In (c) `col_idx` concatena le righe di (b), `row_ptr[v]` indica dove ciascuna comincia e `out_deg` conserva i denominatori. Le due condizioni limite sono distinte e vivono su array distinti: la riga 4 è vuota perché nessuno punta al nodo 4, mentre `out_deg[3]` è nullo perché il nodo 3 non ha archi uscenti.

Perché il trasposto. Importante la scelta di quale indice diventa la riga. L'equazione (1) richiede, per calcolare $PR_{t+1}(v)$, l'insieme dei nodi che puntano a v . Esistono due modi di organizzare il calcolo:

Push si scorre l'insieme degli archi $u \rightarrow v$ e si somma il contributo di u dentro $PR'(v)$. Più archi convergono sullo stesso v , quindi più thread scrivono sulla stessa cella: si genera una *race condition* che richiede operazioni atomiche o lock.

Pull si scorre l'insieme dei nodi v , si leggono i suoi predecessori e si scrive $PR'(v)$ una sola volta. Ogni nodo è di competenza di un solo thread: **non esiste alcuna scrittura concorrente**.

È stata adottata la formulazione *pull*, che richiede di memorizzare, per ogni nodo, la lista dei predecessori — cioè il grafo con tutti gli archi invertiti, il *trasposto*. È quanto illustra la Figura 1: la riga v raccoglie gli archi *entranti* in v , non quelli uscenti. L'inversione non richiede un passo dedicato: costruendo il CSR si sceglie semplicemente il nodo di destinazione, anziché quello di origine, come indice di riga.

Costo in memoria e modo di accesso. La struttura occupa $8 \times (N+1) + 4 \times M + 4 \times N$ byte, ed è questa formula a produrre l'ultima colonna della Tabella 2: per **web-Goog1e** 29,5 MiB contro i 5,6 TiB della matrice densa. Resta però un aspetto importante: il ciclo tocca tre array, e li tocca in due modi diversi. `row_ptr` e `col_idx` si leggono in ordine, $v = 0, 1, 2, \dots$ e dentro ogni riga $j = 0, 1, 2, \dots$; il processore se ne accorge e fa *prefetch*,¹ cosicché quando si arriva a quelle celle siano già in cache e l'attesa sia quasi nulla. Con `contrib[col_idx[j]]` non succede: l'indice arriva da `col_idx`, quindi si salta in un punto qualsiasi — nell'esempio della Figura 1 prima `contrib[1]`, poi `contrib[4]`, poi `contrib[0]` — e il prefetch non ha modo di indovinare dove. Ogni accesso rischia così di aspettare la RAM, molto più lenta della cache.

Per ogni arco si va a prendere un contributo in una posizione imprevedibile e si esegue una sola somma: tanto traffico di memoria, pochissima aritmetica. In teoria il calcolo dovrebbe risultare *memory-bound*, e la Sezione 3.4 verifica se è davvero così.

2.3 Formato binario e pre-elaborazione

I grafi della collezione SNAP sono distribuiti come file di testo. Dopo l'intestazione seguono gli archi, uno per riga, come due interi separati da un carattere di tabulazione:

```
# Directed graph (each unordered pair of nodes is saved once): Wiki-Vote.txt
# Wikipedia voting on promotion to administratorship (till January 2008).
...
# Nodes: 7115 Edges: 103689
# FromNodeId      ToNodeId
30      1412
30      3352
30      5254
```

Il primo intero è il nodo di partenza, il secondo quello di arrivo: ogni riga è dunque un arco orientato. Non c'è un elenco esplicito dei nodi — esistono quelli che compaiono in almeno un arco — e il formato non garantisce né che gli identificatori siano contigui, né che le righe siano ordinate, né che uno stesso arco non compaia due volte.

La conversione dal formato testuale SNAP al CSR avviene *una volta sola*, offline: l'analisi del testo è lenta e irregolare, ed eseguirla dentro il programma misurato significherebbe misurare

¹Riconosciuto un andamento regolare negli accessi alla memoria, il processore porta in cache le celle successive prima che il programma le chieda. Funziona sugli accessi sequenziali; su quelli imprevedibili non ha nulla su cui basarsi.

il parser anziché l'algoritmo. Si tratta di sola preparazione dei dati e il risultato è l'input del programma vero e proprio, non una sua parte: il convertitore `tools/snap_to_csr.py` è scritto in Python per comodità, dato che numpy risolve in poche righe la rimappatura degli identificatori e l'ordinamento degli archi.

Gli identificatori SNAP sono sparsi (`web-Google` ha 875 713 nodi con id fino a 916 428) e vengono rimappati su un intervallo contiguo $[0, N]$; la corrispondenza inversa è salvata in un file `.ids` separato, letto solo per riportare i risultati negli identificatori originali.

Per conservare il risultato si è scelto un formato binario invece che testuale. Due ragioni a favore:

- *velocità*: leggere il binario è solo copiare byte,² perché i byte del file sono già nella forma in cui il programma li usa, senza niente da interpretare, mentre in testo servirebbe un parser in C che a ogni esecuzione rilegga e riconverta i numeri cifra per cifra;
- *dimensione*: in binario un numero occupa i byte del suo tipo, in testo un carattere per cifra più il separatore.

E due prezzi da pagare:

- *leggibilità*: il file non si apre con un editor per dargli un'occhiata; per guardare dentro un grafo convertito serve uno strumento apposta, ed è `src/csr_info.c`;
- *errori silenziosi*: qualunque sequenza di byte può essere un CSR valido, sicché un file corrotto o troncato viene letto lo stesso e produce risultati sbagliati senza avvisare. Un testo malformato invece è più facile da rilevare: chi lo legge trova un carattere dove si aspettava una cifra, e si ferma. È per questo che `src/csr.c` ha il magic number e i cinque controlli della Sezione 2.5.

Il grafo è scritto in un file `.csr`, nel formato binario seguente:

Campo	Tipo	Dimensione
magic "PRCSR001"	char[8]	8 byte
n_nodes	uint64	8 byte
n_edges	uint64	8 byte
row_ptr	uint64[]	$8(N+1)$ byte
col_idx	uint32[]	$4M$ byte
out_deg	uint32[]	$4N$ byte

I primi otto byte identificano il formato: il caricatore li confronta e rifiuta subito un file che non sia un `.csr`, invece di interpretarne i primi byte come dimensioni. Le tre cifre finali sono un numero di versione.

Per ciascuno dei tre array resta da decidere quanti byte dare a ogni singolo numero, 4 oppure 8. Servono due informazioni, ed è bene tenerle distinte: *quante celle* ha l'array, che dice quanto si guadagna a stringerlo, e *quanto valgono* i numeri che vi finiscono dentro, che dice se stringerlo è possibile. In 4 byte sta qualunque valore fino a circa 4,3 miliardi.

Array	Celle	Contenuto di una cella	Valore massimo
col_idx	M , una per arco	l'indice di un nodo	$N - 1$
row_ptr	$N+1$, una per nodo	una posizione dentro col_idx	M
out_deg	N , una per nodo	il grado uscente del nodo	$N - 1$

²Il caricamento si riduce a una `fread` per array.

Le prime due righe sono incrociate: `col_idx` ha molte celle e valori piccoli, `row_ptr` poche celle e valori grandi. Su `soc-LiveJournal1` le celle sono 69 milioni (archi) contro 4,8 milioni (nodi).

`col_idx` usa perciò 32 bit. Si può, perché dentro ci sono indici di nodo e il più alto è solo 4847571. E conviene, perché le celle sono M : i 4 byte risparmiati su ognuna valgono 263 MiB su un file che in tutto ne pesa 318,7. `row_ptr` resta invece a 64 bit. Stringerlo sarebbe possibile — 69 milioni in 4 byte ci sta — ma rende poco e costa un limite. Rende poco perché le celle sono quattordici volte meno: 18 MiB invece di 263. Costa un limite perché dentro ci sono posizioni nell'array degli archi, che crescono velocemente con M . `out_deg` sta a 32 bit come `col_idx`, perché ha un valore massimo che non supera N , e in più la scelta pesa poco perché, come `row_ptr`, ha N celle. Il tipo stretto va insomma dove le celle sono tante e i valori piccoli, quello largo dove le celle sono poche e i valori possono crescere.

Il guadagno atteso, poi, non è tanto sul disco quanto sul traffico di memoria: per ogni arco il ciclo legge un elemento di `col_idx` ed esegue una sola moltiplicazione-somma, cosicché portare ogni cella da 8 a 4 byte dimezza i byte letti in sequenza.

2.4 Precisione: float contro double

Bisogna decidere anche quanti byte dare a ogni numero dei tre vettori dell'Algoritmo 1 — `PR`, `PR'` e `contrib` — che non fanno parte del `.csr` ma vivono solo in memoria, e condividono un unico tipo, definito da un `typedef` che si può cambiare in fase di compilazione con `-DPAGERANK_FLOAT`. La motivazione è che sulle GPU di fascia consumer l'aritmetica FP32 (`float`, 4 byte) è nettamente più veloce della FP64 (`double`, 8 byte). Il kernel CUDA richiederà perciò verosimilmente `float`; mantenere entrambe le varianti raggiungibili dallo stesso sorgente permette di confrontarne accuratezza e velocità.

Gli accumulatori — `accum_t` nel codice — restano invece sempre in `double`. Sono tre sole variabili scalari: la somma dei contributi di un nodo, la massa dangling e la variazione ε fra due iterazioni. Tenerle larghe non costa quindi traffico di memoria, mentre stringerle costerebbe accuratezza.

2.5 Validazione del file in ingresso

Il caricatore in `src/csr.c` verifica cinque proprietà del file prima di dichiarare riuscito il caricamento:

- `check_header_counts` — i conteggi dichiarati sono compatibili con la dimensione del file;
- `check_header_size` — il file misura esattamente quanto l'intestazione implica;
- `check_rowptr_span` — i due estremi di `row_ptr`: il primo offset vale 0, l'ultimo vale M ;
- `check_rowptr_monotonic` — gli offset non decrescono, il che insieme al controllo precedente li confina tutti in $[0, M]$;
- `check_neighbours_are_existing_nodes` — ogni vicino memorizzato è un nodo esistente.

I controlli fatti in fase di caricamento permettono al programma di assumere che i dati siano corretti e di non verificare nulla dentro i cicli di calcolo (`pagerank.c`).

2.6 Implementazione sequenziale e OpenMP

Le due versioni condividono lo stesso file sorgente `pagerank.c` poiché le direttive OpenMP sono ignorate dal compilatore quando non gli si passa `-fopenmp`, che produce quindi un programma sequenziale. Oltre a non esistere così duplicazione di codice che possa divergere, il riferimento sequenziale è *onesto*: misurando la versione parallela limitata a un thread si otterrebbe un tempo peggiore (Tabella 3, colonna *1 thr*), perché si pagherebbe comunque la creazione del team di thread: usarla come riferimento gonfierebbe silenziosamente ogni speed-up dichiarato.

Il nucleo contiene due cicli paralleli per iterazione.

```
1 | #pragma omp parallel for schedule(static) reduction(+ : dangling)
2 | for (v = 0; v < n; v++) {
3 |     if (g->out_deg[v] == 0) {
4 |         contrib[v] = 0;
5 |         dangling += cur[v];
6 |     } else {
7 |         contrib[v] = cur[v] / g->out_deg[v];
8 |     }
9 | }
```

Listing 1: Calcolo dei contributi e massa dangling.

La clausola `reduction(+ : dangling)` assegna a ogni thread una copia privata della variabile, inizializzata a zero, e ne somma i valori al termine del ciclo. È la soluzione corretta e veloce al problema dell'aggiornamento concorrente: una variabile condivisa protetta da lock serializzerebbe l'intero ciclo. Lo scheduling è `static` perché il lavoro per iterazione è costante.

```
1 | #pragma omp parallel for schedule(dynamic, 256) reduction(+ : error)
2 | for (v = 0; v < n; v++) {
3 |     accum_t sum = 0.0;
4 |     for (j = g->row_ptr[v]; j < g->row_ptr[v + 1]; j++)
5 |         sum += contrib[g->col_idx[j]];
6 |     nxt[v] = base + d * sum;
7 |     error += fabs(nxt[v] - cur[v]);
8 | }
```

Listing 2: Accumulo dai predecessori (CSR).

La clausola `reduction` su `error` funziona allo stesso modo, mentre lo scheduling è `dynamic`: la lunghezza delle righe varia di ordini di grandezza, quindi una suddivisione statica assegnerebbe a ogni thread lo stesso *numero di righe* ma non la stessa *quantità di lavoro*, lasciando inattivi i thread che hanno ricevuto solo nodi di grado basso. La dimensione del blocco (256) è un parametro che va calibrato provando.

Alternanza dei buffer. L'iterazione alterna due vettori (`rank` e `next`) scambiando due puntatori (`cur`, che indica sempre i punteggi più recenti, e `nxt`, dove si scrivono quelli nuovi) anziché copiare i dati; una sola `memcpy` finale è necessaria, e solo se il numero di scambi è dispari.

2.7 Implementazione ibrida OpenMP + CUDA

[DA COMPLETARE] Sezione da scrivere interamente. Dovrà documentare: partizionamento del carico fra V_{host} e V_{device} in base al grado dei nodi; copiare i dati sulla GPU mentre il calcolo è già in corso, usando stream creati esplicitamente e `cudaMemcpyAsync`; combinazione dell'errore di convergenza calcolato su CPU e GPU; dimensionamento di griglia e blocchi a runtime tramite `cudaGetDeviceProperties` e `cudaMemGetInfo`, come richiesto dal requisito di portabilità; granularità adattiva (un thread, un warp o un blocco per riga a seconda della sua lunghezza).

Perché una granularità variabile. La distribuzione delle lunghezze di riga, misurata da `csr_info.c`, è riportata in Tabella 1: nei tre grafi maggiori fra il 45% e il 64% delle righe contiene al più 4 elementi, mentre singole righe raggiungono decine di migliaia. Questo giustifica quantitativamente la scelta: invece di assegnare sempre un thread a ogni riga, a seconda della sua lunghezza le si assegna un thread, un warp o un blocco intero, che si dividono gli elementi della riga.

Tabella 1: Distribuzione delle lunghezze di riga (predecessori per nodo).

Grafo	0	1–4	5–32	> 32	max
wiki-Vote	66,5 %	3,0 %	12,9 %	17,6 %	457
web-Google	18,4 %	56,7 %	22,3 %	2,6 %	6 326
web-BerkStan	9,9 %	64,2 %	22,6 %	3,3 %	84 208
soc-LiveJournal1	7,4 %	45,2 %	36,7 %	10,7 %	13 906

2.8 Strategia di verifica

Il programma produce milioni di valori, non ispezionabili a occhio. La correttezza è quindi stabilita ricalcolando il risultato per vie che non condividono codice con l’implementazione sotto esame (`tools/verify_pagerank.py`):

1. il file CSR binario viene confrontato con una rilettura indipendente dell’edge list, effettuata in Python puro;
2. PageRank viene ricalcolato su una **matrice densa** $N \times N$ mediante iterazione di potenza: nessun CSR, nessun ciclo di accumulo, quindi un errore nella rappresentazione sparsa non può sopravvivere al confronto;
3. il riferimento denso viene a sua volta confrontato con **NetworkX**, implementazione di terze parti. Questo passo esclude una classe di errori che i primi due non coprono: il riferimento denso è indipendente nel metodo ma scritto sempre da me, quindi un fraintendimento dell’algoritmo potrebbe essere riprodotto identico in entrambi;
4. si verifica infine che il binario C sia *giunto a convergenza*, che la somma dei rank sia 1 e che il risultato coincida: sia relativamente a *tutti* i valori, sia per quanto riguarda l’ordine dei primi $k = 100$ nodi.

Poiché la matrice densa richiede N^2 elementi, il punto 2 è possibile solo sul grafo più piccolo: 386 MiB per **wiki-Vote** contro i 5,6 TiB che servirebbero per **web-Google**. È questa la ragione per cui **wiki-Vote** fa parte dell’insieme di test.

I due piani del punto 4 colgono cose diverse. Il confronto sui valori intercetta un punteggio sbagliato ovunque si trovi, anche in fondo alla classifica dove non sposterebbe la somma. Quello sull’ordine verifica la cosa per cui PageRank esiste, ma ha senso solo in testa: più in giù i punteggi si addensano fino a coincidere — i 4734 nodi di **wiki-Vote** senza archi entranti hanno tutti lo stesso valore — e l’ordine fra pari dipende solo da come l’ordinamento spezza i pareggi. Uno scambio viene perciò segnalato come errore soltanto se avviene fra valori effettivamente distinti.

Il controllo di convergenza al punto 4 non è ridondante: forzando l’arresto dopo 5 iterazioni il *ranking* dei primi risultati è ancora corretto mentre i valori sono lontani dall’essersi stabilizzati, quindi verificare solo l’ordinamento accetterebbe un risultato quantitativamente sbagliato.

L'opzione `--no-dense` rinuncia a quel punto e confronta il binario direttamente con NetworkX, che non ha il vincolo quadratico. Si perde la capacità di localizzare un eventuale errore — è il livello che fallisce a dire se il difetto stia nell'implementazione o nella comprensione dell'algoritmo — ma la verifica diventa possibile sui grafi maggiori: **web-Google** e **web-BerkStan**. Su entrambi il binario concorda con NetworkX su tutti i valori entro $7 \cdot 10^{-11}$, e sul ranking dei primi cento nodi a meno di scambi fra punteggi identici.

3 Risultati sperimentali

3.1 Ambiente di prova

Sistema operativo	Ubuntu 22.04.5 LTS, kernel Linux 6.8
CPU	Intel Core i5-9300H, 4 core fisici / 8 thread, 2,40–4,10 GHz
Cache	L1d 128 KiB, L2 1 MiB, L3 8 MiB
RAM	15 GiB
GPU	NVIDIA GeForce GTX 1050 Ti, 4 GiB, compute capability 6.1, 6 SM
Compilatore	gcc, OpenMP 4.5; CUDA Toolkit 12.8
Opzioni	<code>-std=c11 -Wall -Wextra -O2</code>

Tutti i binari compilano senza alcun avviso.

[DA COMPLETARE] Utilizzare anche altre macchine

3.2 Istanze di prova

Sono stati usati quattro grafi reali della collezione SNAP [3], scelti in modo da coprire circa tre ordini di grandezza nel numero di archi (fattore $670\times$ fra il minimo e il massimo).

Tabella 2: Istanze utilizzate.

Grafo	Nodi	Archivi	Dangling	max in-deg	CSR
wiki-Vote	7 115	103 689	1 005	457	0,5 MiB
web-Google	875 713	5 105 039	136 259	6 326	29,5 MiB
web-BerkStan	685 230	7 600 595	4 744	84 208	36,8 MiB
soc-LiveJournal1	4 847 571	68 993 773	539 119	13 906	318,7 MiB

I due grafi web sollecitano aspetti diversi: **web-BerkStan** ha un singolo *hub* estremo (84 208 archi entranti), mentre **soc-LiveJournal1** ha la distribuzione più pesante nella fascia intermedia (Tabella 1).

3.3 Correttezza

Confronto	Accordo	Esclude
C contro riferimento denso	$7,1 \cdot 10^{-14}$	errori in CSR o nel ciclo di accumulo
C contro NetworkX, grafi maggiori	$6,5 \cdot 10^{-11}$	errori visibili solo su scala grande
NetworkX contro denso	$4,5 \cdot 10^{-12}$	fraintendimenti dell'algoritmo
OpenMP contro sequenziale	$2,1 \cdot 10^{-14}$	race condition
float contro double	$2,2 \cdot 10^{-7}$	perdita di precisione anomala
Somma dei rank (ogni prova)	1,000000	dispersione della massa dangling

Lo scarto relativo fra OpenMP e sequenziale è dovuto unicamente al diverso ordine di somma introdotto dalla riduzione. Lo scarto della versione **float** coincide con l'epsilon di macchina

della singola precisione ($1,19 \cdot 10^{-7}$): non si perde quindi nulla oltre al limite intrinseco del formato.

3.4 Scalabilità della versione OpenMP

Ogni configurazione è stata eseguita tre volte; si riporta il *minimo*, perché l'attività di sistema può solo rallentare un'esecuzione, mai accelerarla, e la prova più rapida è quindi la meno disturbata.

Tabella 3: Tempi di esecuzione in secondi (minimo su 3 ripetizioni).

Grafo	seq	1 thr	2 thr	4 thr	8 thr	float 8	speed-up
web-Google	1,326	1,353	0,741	0,459	0,519	0,347	2,89×
web-BerkStan	0,715	0,712	0,400	0,254	0,269	0,214	2,82×
soc-LiveJournal1	11,863	12,442	7,457	5,088	5,014	3,608	2,37×




Figura 2: Scalabilità della versione OpenMP. Il riferimento per lo speed-up è la build sequenziale vera, compilata senza `-fopenmp`. La linea tratteggiata in (a) indica lo speed-up lineare ideale; in (b) l'efficienza del 100 %. Su *web-Google* e *web-BerkStan* il passaggio da 4 a 8 thread *peggiora* il tempo di esecuzione. Figura generata da `tools/plot_results.py` a partire da `results/bench.csv`.

La Figura 2 rende visibile il fenomeno descritto sopra: le tre curve si allontanano dall'andamento lineare già a 2 thread e si appiattiscono fra 4 e 8, con una vera e propria inversione su due grafi su tre. L'efficienza scende dal 90 % circa a 2 thread al 70 % a 4, fino a circa il 30 % a 8: i thread aggiuntivi non trovano banda di memoria disponibile.

Osservazione principale: il calcolo è memory-bound. Su due grafi su tre l'esecuzione con 8 thread è *più lenta* di quella con 4. Il processore possiede 4 core fisici presentati come 8 thread logici; i due thread che condividono un core condividono anche la via di accesso alla memoria. Poiché il ciclo interno passa la maggior parte del tempo in attesa di letture sparse su `contrib`, i thread aggiuntivi producono contesa anziché capacità di calcolo.

L'efficienza parallela su 4 core è del 60–72%. Questo risultato è il dato più importante dell'analisi: identifica il collo di bottiglia nella *larghezza di banda della memoria*, non nella

potenza di calcolo, e costituisce la motivazione quantitativa per il passaggio alla GPU — il cui vantaggio non è tanto il maggior numero di core quanto la banda di memoria sensibilmente superiore.

Nota sull'istanza più piccola. I tempi di `wiki-Vote` non sono riportati in Tabella 3: con durate dell'ordine del millesimo di secondo la dispersione fra ripetizioni della stessa configurazione raggiunge un fattore $51\times$, il che significa che si misurerebbe l'avvio del team di thread e non l'algoritmo. Il grafo resta nell'insieme di prova con il ruolo di riferimento di correttezza (Sezione 2.8).

3.5 Confronto fra le varianti `float` e `double`

La variante in singola precisione è più rapida del 32% su `web-Google` (0,347 s contro 0,459 s), a parità di numero di iterazioni e con ranking identico. Il guadagno è coerente con il dimezzamento dei byte trasferiti per ogni rank, ed è un'ulteriore conferma indiretta della natura memory-bound del calcolo.

Il limite della singola precisione si manifesta sulla soglia di convergenza: su `web-Google` l'errore L_1 non scende sotto $\approx 5 \cdot 10^{-9}$, per cui una tolleranza di 10^{-9} non viene mai raggiunta mentre la doppia precisione converge in 104 iterazioni. Alla tolleranza utilizzata negli esperimenti (10^{-6}) entrambe convergono nello stesso numero di iterazioni.

3.6 Risultati della versione ibrida

[DA COMPLETARE] Sezione da scrivere: tempi della versione CUDA e ibrida, confronto con OpenMP, occupancy, effetto della granularità adattiva, effetto della sovrapposizione fra trasferimenti e calcolo.

4 Valutazioni e osservazioni

4.1 Punti di forza

- **Assenza di sincronizzazione nel nucleo di calcolo.** La formulazione *pull*, con il grafo memorizzato trasposto, elimina alla radice le scritture concorrenti, e si trasferisce invariata alla versione CUDA.
- **Riferimento sequenziale onesto.** Sequenziale e parallelo provengono dallo stesso sorgente, il che rende impossibile una divergenza fra le due versioni e non gonfia lo speed-up dichiarato.
- **Verifica indipendente e collaudata.** Tre implementazioni concordano, e lo strumento di verifica è stato validato con un'iniezione di guasto.
- **Riproducibilità.** L'intera campagna sperimentale è riproducibile con un solo comando.

4.2 Punti deboli e limiti

- **Il convertitore non scala oltre le istanze usate.** Il convertitore Python mantiene l'intera edge list in memoria, con un costo di circa 100 byte per arco misurato su `soc-LiveJournal1`. Un'istanza da un miliardo di archi ne richiederebbe un centinaio di gigabyte, e servirebbe un convertitore in C con ordinamento esterno.
- **Formato binario non standard.** Il formato `.csr` è specifico del progetto: è velocissimo da caricare, ma non ispezionabile con strumenti esterni. La scelta è stata fatta consapevolmente, privilegiando l'assenza di parsing nel percorso misurato.

- **Dimensione della porzione dinamica non ottimizzata.** Il valore 256 di `schedule(dynamic, 256)` non è stato oggetto di una ricerca sistematica.

4.3 Possibili miglioramenti

- **Gestione out-of-core.** Era prevista in fase di proposta una logica di streaming per grafi eccedenti la memoria della GPU. Le misure hanno mostrato che non è necessaria per le istanze considerate: il grafo più grande occupa 356 MiB contro i 4 GiB disponibili, e servirebbe un'istanza dell'ordine del miliardo di archi per superare la soglia. Resta un possibile sviluppo futuro, subordinato però alla riscrittura del convertitore.
- **Granularità adattiva sulla GPU.** Le misure di Tabella 1 sono già disponibili ma non ancora sfruttate da alcun kernel.
- **Reciproci del grado precalcolati.** Il ciclo dei contributi esegue N divisioni per iterazione; un array `inv_out_deg[N]` con $1/\text{outdeg}(u)$ calcolato una volta sola le ridurrebbe ad altrettante moltiplicazioni. Su CPU il guadagno atteso è piccolo — quel ciclo tocca N elementi contro gli M del ciclo di accumulo, e il calcolo è comunque *memory-bound* — e in doppia precisione l'array costerebbe $8 \times N$ byte contro i $4 \times N$ di `out_deg`, raddoppiando il traffico proprio dove sta il collo di bottiglia. Vale invece la pena provarlo sulla GPU e nella variante `float`, dove il rapporto di costo fra divisione e moltiplicazione è più sfavorevole e l'occupazione resta invariata. Da verificare l'effetto sulla precisione: $x \cdot (1/d)$ introduce un arrotondamento in più rispetto a x/d .
- **Ricerca sui parametri di scheduling** (politica e dimensione del blocco) e confronto con `guided`.

[DA COMPLETARE] Aggiungere la valutazione personale complessiva una volta completata la fase CUDA.

5 Guida all'uso e riproducibilità

5.1 Requisiti

`gcc` con supporto OpenMP; CUDA Toolkit per la versione ibrida; Python 3 con `numpy` per la conversione dei dataset, più `networkx` e `scipy` per la sola verifica di correttezza.

5.2 Compilazione

```
| make
```

Produce quattro eseguibili in `build/`: `pagerank_seq` (senza OpenMP), `pagerank_omp`, `pagerank_omp_float` e `csr_info`. Tutti derivano dagli stessi file sorgente.

5.3 Preparazione dei dati

```
| mkdir -p data/snap && cd data/snap
| for g in wiki-Vote web-Google web-BerkStan soc-LiveJournal1; do
|     curl -O https://snap.stanford.edu/data/$g.txt.gz && gunzip $g.txt.gz
| done
| cd ../../
| python3 tools/snap_to_csr.py data/snap/web-Google.txt
```

5.4 Esecuzione

```
| ./build/pagerank_omp data/snap/web-Google.csr -i data/snap/web-Google.ids
```

Opzioni: `-d` damping, `-t` tolleranza, `-n` iterazioni massime, `-k` quanti nodi stampare, `-o` salva tutti i rank, `-c` accoda una riga CSV con i dati dell'esecuzione. Il numero di thread si imposta con `OMP_NUM_THREADS`.

5.5 Verifica della correttezza

```
| python3 tools/verify_pagerank.py data/snap/wiki-Vote.txt  
| python3 tools/verify_pagerank.py data/snap/web-Google.txt --no-dense
```

Termina con stato diverso da zero in caso di discrepanza, e può quindi essere usato come test di regressione. La seconda forma salta il riferimento denso, che richiederebbe N^2 elementi, e confronta il binario con il solo NetworkX: è il modo di verificare i grafi troppo grandi per la prima.

5.6 Riproduzione degli esperimenti

```
| tools/run_benchmarks.sh
```

Esegue ogni grafo con le varianti sequenziale, OpenMP (1/2/4/8 thread) e float, con tre ripetizioni, e scrive `results/bench.csv` (una riga per esecuzione) e i vettori dei rank completi. Le impostazioni sono sovrascrivibili da ambiente, ad esempio `GRAPHS="wiki-Vote" REPS=1 tools/run_benchmarks.sh`.

5.7 Codice sorgente

Il codice completo, con la cronologia di sviluppo, è disponibile all'indirizzo

<https://github.com/EmanueleCecchia/pagerank-openmp-cuda>

Il repository contiene i sorgenti C, gli strumenti Python di conversione e verifica, lo script della campagna sperimentale e il file `results/bench.csv` con i dati grezzi di tutte le esecuzioni. I dataset e i vettori dei rank non sono versionati per ragioni di dimensione: i primi si ricaricano con i comandi della Sezione 5.3, i secondi si rigenerano con `tools/run_benchmarks.sh`.

Riferimenti bibliografici

- [1] L. Page, S. Brin, R. Motwani, T. Winograd, *The PageRank Citation Ranking: Bringing Order to the Web*, Stanford InfoLab, 1999.
- [2] V. Visali, R. Manimegalai, S. Noor Mahammad, A. Sunitha Nandhini, *Performance Analysis of Parallelized PageRank Algorithm using OpenMP, MPI and CUDA*, ICSSECC, pp. 44–49, IEEE, 2024.
- [3] J. Leskovec, A. Krevl, *SNAP Datasets: Stanford Large Network Dataset Collection*, <https://snap.stanford.edu/data>, 2014.
- [4] D. B. Kirk, W. W. Hwu, *Programming Massively Parallel Processors*, 3rd ed., Morgan Kaufmann, 2016.
- [5] NVIDIA, *CUDA C++ Programming Guide*.