

PageRank su Architetture Ibride

Parallelizzazione con OpenMP e CUDA

Emanuele Cecchia

Corso di Programmazione su Architetture Parallele

A.A. 2025–26 — Prof. Andrea Formisano

7 settembre 2026

Abstract

Il progetto implementa e analizza l'algoritmo PageRank su architetture parallele, confrontando una versione puramente multicore basata su OpenMP con una versione ibrida che distribuisce il carico fra CPU e GPU tramite CUDA. Il grafo è memorizzato in formato CSR trasposto, scelta che rende il nucleo di calcolo privo di scritture concorrenti e quindi parallelizzabile senza sincronizzazione. La correttezza è verificata contro tre implementazioni indipendenti. Le misure sulla versione OpenMP mostrano uno speed-up di $2,4\text{--}2,9\times$ su 4 core fisici e, soprattutto, una saturazione oltre i 4 thread che identifica il calcolo come *memory-bound*: è questo il dato che motiva quantitativamente il passaggio alla GPU.

[DA COMPLETARE] Aggiornare l'abstract con i risultati CUDA una volta completata la fase ibrida.

Indice

1	Descrizione del problema affrontato	2
1.1	Il problema	2
1.2	Il termine dangling	2
1.3	Algoritmo sequenziale	2
1.4	Necessità della parallelizzazione	3
2	Metodologia adottata per la soluzione	3
2.1	Rappresentazione dei dati: CSR trasposto	3
2.2	Formato binario e pre-elaborazione	3
2.3	Struttura del codice	4
2.4	Validazione del file in ingresso	4
2.5	Implementazione sequenziale e OpenMP	5
2.6	Precisione: <code>float</code> contro <code>double</code>	6
2.7	Implementazione ibrida OpenMP + CUDA	6
2.8	Strategia di verifica	6
3	Risultati sperimentali	7
3.1	Ambiente di prova	7
3.2	Istanze di prova	7
3.3	Correttezza	8
3.4	Scalabilità della versione OpenMP	8

3.5	Confronto fra le varianti <code>float</code> e <code>double</code>	9
3.6	Risultati della versione ibrida	9
4	Valutazioni e osservazioni	9
4.1	Punti di forza	9
4.2	Punti deboli e limiti	10
4.3	Possibili miglioramenti	10
5	Guida all'uso e riproducibilità	10
5.1	Requisiti	10
5.2	Compilazione	10
5.3	Preparazione dei dati	10
5.4	Esecuzione	11
5.5	Verifica della correttezza	11
5.6	Riproduzione degli esperimenti	11
5.7	Codice sorgente	11

1 Descrizione del problema affrontato

1.1 Il problema

PageRank assegna a ogni nodo di un grafo orientato un punteggio di importanza, definito ricorsivamente: un nodo è importante se nodi importanti puntano ad esso. Nato per ordinare le pagine web in base alla struttura dei collegamenti ipertestuali [1], viene oggi applicato anche a reti sociali, reti di citazioni e reti biologiche.

Formalmente, dato un grafo orientato $G = (V, E)$ con $N = |V|$, il vettore dei rank π è il punto fisso dell'iterazione

$$\pi_{t+1}(v) = \frac{1-d}{N} + d \left(\sum_{u: u \rightarrow v} \frac{\pi_t(u)}{\text{outdeg}(u)} + \frac{D_t}{N} \right) \quad (1)$$

dove d è il *damping factor* (convenzionalmente 0,85) e $D_t = \sum_{u: \text{outdeg}(u)=0} \pi_t(u)$ è la massa di rank che si trova sui nodi *dangling*, cioè privi di archi uscenti.

1.2 Il termine dangling

Il termine D_t/N non è un dettaglio implementativo ma una necessità matematica. Un nodo senza archi uscenti non ha modo di ridistribuire il proprio rank: ignorandolo, ad ogni iterazione una frazione della massa totale sparirebbe e il vettore cesserebbe di essere una distribuzione di probabilità. Nei dataset utilizzati questo non è un caso limite: il 15,6% dei nodi di **web-Google** e l'11,1% di **soc-LiveJournal1** sono *dangling* (Tabella 2).

La conseguenza pratica è che $\sum_v \pi(v) = 1$ costituisce un test di correttezza immediato e molto sensibile: il programma lo stampa ad ogni esecuzione.

1.3 Algoritmo sequenziale

Algorithm 1 PageRank per iterazione di potenza (formulazione *pull*)

```
1:  $\pi(v) \leftarrow 1/N$  per ogni  $v \in V$ 
2: repeat
3:    $D \leftarrow 0$ 
4:   for all  $u \in V$  do
5:     if  $\text{outdeg}(u) = 0$  then
6:        $c(u) \leftarrow 0$ ;  $D \leftarrow D + \pi(u)$ 
7:     else
8:        $c(u) \leftarrow \pi(u)/\text{outdeg}(u)$ 
9:     end if
10:  end for
11:   $base \leftarrow (1-d)/N + d \cdot D/N$ 
12:  for all  $v \in V$  do
13:     $\pi'(v) \leftarrow base + d \sum_{u \rightarrow v} c(u)$ 
14:  end for
15:   $\varepsilon \leftarrow \sum_v |\pi'(v) - \pi(v)|$ 
16:  scambia  $\pi$  e  $\pi'$ 
17: until  $\varepsilon < \text{tolleranza}$ 
```

Il calcolo di $c(u)$ è separato dal ciclo di accumulo per una ragione di costo: eseguito così richiede N divisioni per iterazione anziché $M = |E|$, e nei grafi considerati $M \gg N$ (su **soc-LiveJournal1**, 69 milioni contro 4,8 milioni). La divisione è fra le operazioni aritmetiche più lente, quindi il risparmio è reale.

1.4 Necessità della parallelizzazione

La difficoltà del problema è interamente di scala. Il grafo non può essere rappresentato con una matrice densa $N \times N$: per **web-Google** servirebbero $875\,713^2 \times 8 \text{ byte} \approx 5,6 \text{ TB}$, di cui oltre il 99,99% occupati da zeri, dato che il grado medio è circa 6. È quindi necessaria una rappresentazione sparsa, e il calcolo va distribuito su più unità di elaborazione per ottenere tempi accettabili al crescere dell'istanza.

2 Metodologia adottata per la soluzione

2.1 Rappresentazione dei dati: CSR trasposto

Il grafo è memorizzato in formato **CSR** (Compressed Sparse Row) con tre array:

- `row_ptr[N+1]`: offset di inizio di ogni riga;
- `col_idx[M]`: i vicini, concatenati riga per riga;
- `out_deg[N]`: grado uscente di ogni nodo.

I vicini del nodo v occupano `col_idx[row_ptr[v] ... row_ptr[v+1]-1]`. Un nodo privo di vicini ha `row_ptr[v] == row_ptr[v+1]`: il ciclo semplicemente non viene eseguito, senza bisogno di alcun caso speciale.

Perché il trasposto. La scelta progettuale più importante del progetto è *quale* indice diventa la riga. L'equazione (1) richiede, per calcolare $\pi_{t+1}(v)$, l'insieme dei nodi che puntano a v . Esistono due modi di organizzare il calcolo:

Push si scorre l'insieme degli archi $u \rightarrow v$ e si somma il contributo di u dentro $\pi'(v)$. Più archi convergono sullo stesso v , quindi più thread scrivono sulla stessa cella: si genera una *race condition* che richiede operazioni atomiche o lock.

Pull si scorre l'insieme dei nodi v , si leggono i suoi predecessori e si scrive $\pi'(v)$ una sola volta. Ogni nodo è di competenza di un solo thread: **non esiste alcuna scrittura concorrente**.

È stata adottata la formulazione *pull*, che richiede di memorizzare, per ogni nodo, la lista dei predecessori — cioè il grafo con tutti gli archi invertiti, il *trasposto*. L'inversione non richiede un passo dedicato: costruendo il CSR si sceglie semplicemente il nodo di destinazione, anziché quello di origine, come indice di riga.

La motivazione è tanto più forte sulla GPU: le atomiche necessarie alla variante *push* serializzerebbero il kernel proprio sui nodi *hub*, e **web-BerkStan** contiene un nodo con 84 208 archi entranti.

Costo evitato. Con la rappresentazione sparsa **web-Google** occupa 29,5 MB anziché i 5,6 TB della matrice densa.

2.2 Formato binario e pre-elaborazione

La conversione dal formato testuale SNAP al CSR avviene *una volta sola*, offline, tramite `tools/snap_to_csr.py`. Le motivazioni sono due:

1. l'analisi del testo è lenta e irregolare; eseguirla dentro il programma misurato significherebbe misurare il parser anziché l'algoritmo;

2. il codice C non ha così bisogno di alcun parser testuale, il che elimina un'intera classe di errori dalla parte valutata.

Gli identificatori SNAP sono sparsi ([web-Google](#) ha 875 713 nodi con id fino a 916 428) e vengono rimappati su un intervallo contiguo $[0, N]$; la corrispondenza inversa è salvata in un file `.ids` separato, letto solo per riportare i risultati negli identificatori originali.

Il formato binario prodotto è il seguente:

Campo	Tipo	Dimensione
magic "PRCSR001"	char[8]	8 byte
n_nodes	uint64	8 byte
n_edges	uint64	8 byte
row_ptr	uint64[]	$8(N+1)$ byte
col_idx	uint32[]	$4M$ byte
out_deg	uint32[]	$4N$ byte

`col_idx` usa 32 bit anziché 64 perché gli elementi sono M : su [soc-LiveJournal1](#) la scelta dimezza l'occupazione da 552 MB a 276 MB, ed è sicura perché un indice di nodo è sempre minore di $N < 2^{32}$. Il caricamento lato C si riduce così a tre `fread`, senza alcuna conversione.

2.3 Struttura del codice

Modulo	Ruolo	Righe
tools/snap_to_csr.py	conversione SNAP $\rightarrow$ CSR binario	173
src/csr.c, csr.h	caricamento e validazione	293
src/pagerank.c, .h	nucleo di calcolo	186
src/main.c	driver, output, log dei tempi	295
src/csr_info.c	statistiche di un grafo convertito	91
tools/verify_pagerank.py	verifica indipendente	325
tools/run_benchmarks.sh	campagna sperimentale	60

2.4 Validazione del file in ingresso

Il caricatore verifica cinque proprietà prima di restituire il grafo, con altrettante funzioni dal nome esplicito:

- `check_header_counts` — i conteggi dichiarati sono compatibili con la dimensione del file;
- `check_header_size` — il file misura esattamente quanto l'intestazione implica;
- `check_rowptr_span` — gli offset coprono $[0, M]$;
- `check_rowptr_monotonic` — gli offset non decrescono;
- `check_neighbours_are_existing_nodes` — ogni vicino memorizzato è un nodo esistente.

Due meritano una motivazione esplicita.

Confronto fra intestazione e dimensione reale del file. Prima di allocare alcunché si calcola quanti byte il file *dovrebbe* misurare secondo la propria intestazione e lo si confronta con la dimensione effettiva. Un file troncato o corrotto viene così respinto prima che i suoi numeri vengano usati per dimensionare un'allocazione.

Ordine dei controlli come garanzia sintattica. I due controlli sull'intestazione sono concatenati con `||`:

```

1 | if (check_header_counts(g, actual, path) != 0 ||
2 |     check_header_size(g, actual, path) != 0) {
3 |     goto fail;
4 | }
```

La valutazione *short-circuit* garantisce che il secondo controllo non venga mai eseguito su valori che il primo ha già respinto. Questo non è stilistico: è precisamente ciò che impedisce all'aritmetica di `check_header_size` di andare in overflow su un'intestazione corrotta che dichiari, ad esempio, 2^{63} archi. Il vincolo d'ordine è così imposto dal linguaggio anziché essere affidato a un commento.

L'insieme dei controlli rende dimostrabile una proprietà usata dal nucleo di calcolo: il ciclo interno indicizza `contrib[col_idx[j]]` senza alcun controllo proprio di limiti, ed è sicuro solo perché l'invariante è stato stabilito una volta in fase di caricamento.

2.5 Implementazione sequenziale e OpenMP

Le due versioni condividono *lo stesso file sorgente*. Le direttive OpenMP sono ignorate dal compilatore quando non gli si passa `-fopenmp`, che produce quindi normali cicli seriali. Il vantaggio è duplice: non esiste duplicazione di codice che possa divergere, e soprattutto il riferimento sequenziale è *onesto*. Misurando la versione parallela limitata a un thread si otterrebbe un tempo peggiore (Tabella 3, colonna *1 thr*), perché si pagherebbe comunque la creazione del team di thread: usarla come riferimento gonfierebbe silenziosamente ogni speed-up dichiarato.

Il nucleo contiene due cicli paralleli per iterazione.

```

1 | #pragma omp parallel for schedule(static) reduction(+ : dangling)
2 | for (v = 0; v < n; v++) {
3 |     if (g->out_deg[v] == 0) {
4 |         contrib[v] = 0;
5 |         dangling += cur[v];
6 |     } else {
7 |         contrib[v] = cur[v] / g->out_deg[v];
8 |     }
9 | }
```

Listing 1: Calcolo dei contributi e massa dangling.

La clausola `reduction(+ : dangling)` assegna a ogni thread una copia privata della variabile, inizializzata a zero, e ne somma i valori al termine del ciclo. È la soluzione corretta e veloce al problema dell'aggiornamento concorrente: una variabile condivisa protetta da lock serializzerebbe l'intero ciclo. Lo scheduling è `static` perché il lavoro per iterazione è costante.

```

1 | #pragma omp parallel for schedule(dynamic, 256) reduction(+ : error)
2 | for (v = 0; v < n; v++) {
3 |     accum_t sum = 0.0;
4 |     for (j = g->row_ptr[v]; j < g->row_ptr[v + 1]; j++)
5 |         sum += contrib[g->col_idx[j]];
6 |     nxt[v] = base + d * sum;
7 |     error += fabs(nxt[v] - cur[v]);
8 | }
```

Listing 2: Accumulo dai predecessori (CSR).

Qui lo scheduling è `dynamic`: la lunghezza delle righe varia di ordini di grandezza (su `web-BerkStan` da 0 a 84208 elementi), quindi una suddivisione statica assegnerebbe a ogni thread lo stesso *numero di righe* ma non la stessa *quantità di lavoro*, lasciando inattivi i thread che hanno ricevuto solo nodi di grado basso. La dimensione del blocco (256) è un parametro di tuning.

Alternanza dei buffer. L'iterazione alterna due vettori scambiando i puntatori anziché copiare i dati; una sola `memcpy` finale è necessaria, e solo se il numero di scambi è dispari.

2.6 Precisione: float contro double

Il tipo dei rank è definito da un unico `typedef` commutabile in fase di compilazione con `-DPAGERANK_FLOAT`. La motivazione è che le GPU di fascia consumer eseguono l'aritmetica FP64 a una frazione ridotta del ritmo FP32, per cui il kernel CUDA richiederà verosimilmente `float`; mantenere entrambe le varianti raggiungibili dallo stesso sorgente permette di confrontarne accuratezza e velocità.

Gli accumulatori restano però sempre in `double`: memorizzare milioni di rank in singola precisione dimezza il traffico di memoria, ma *sommarli* in singola precisione perderebbe molta più accuratezza di quanta se ne guadagni.

2.7 Implementazione ibrida OpenMP + CUDA

[DA COMPLETARE] Sezione da scrivere interamente. Dovrà documentare: partizionamento del carico fra V_{host} e V_{device} in base al grado dei nodi; orchestrazione con stream CUDA non predefiniti e `cudaMemcpyAsync` per sovrapporre trasferimenti e calcolo; combinazione dell'errore di convergenza calcolato su CPU e GPU; dimensionamento di griglia e blocchi a runtime tramite `cudaGetDeviceProperties` e `cudaMemGetInfo`, come richiesto dal requisito di portabilità; granularità adattiva (un thread, un warp o un blocco per riga a seconda della sua lunghezza).

Dati già disponibili per il progetto del kernel. La distribuzione delle lunghezze di riga, misurata da `csr_info`, è riportata in Tabella 1: fra il 45% e il 64% delle righe contiene al più 4 elementi, mentre singole righe raggiungono decine di migliaia. Questo giustifica quantitativamente uno schema a granularità variabile anziché un kernel monolitico con un thread per riga.

Tabella 1: Distribuzione delle lunghezze di riga (predecessori per nodo).

Grafo	1–4	5–32	> 32	max
wiki-Vote	3,0 %	12,9 %	17,6 %	457
web-Google	56,7 %	22,3 %	2,6 %	6 326
web-BerkStan	64,2 %	22,6 %	3,3 %	84 208
soc-LiveJournal1	45,2 %	36,7 %	10,7 %	13 906

2.8 Strategia di verifica

Il programma produce fino a 4,8 milioni di valori, non ispezionabili a occhio. La correttezza è quindi stabilita ricalcolando il risultato per vie che non condividono codice con l'implementazione sotto esame (`tools/verify_pagerank.py`):

1. il file CSR binario viene confrontato con una rilettura indipendente dell'edge list, effettuata in Python puro;
2. PageRank viene ricalcolato su una **matrice densa** $N \times N$ mediante iterazione di potenza: nessun CSR, nessun ciclo di accumulo, quindi un errore nella rappresentazione sparsa non può sopravvivere al confronto;

3. il riferimento denso viene a sua volta confrontato con **NetworkX**, implementazione di terze parti. Questo passo esclude una classe di errori che i primi due non coprono: il riferimento denso è indipendente nel metodo ma scritto dallo stesso autore del codice in esame, quindi un fraintendimento dell'algoritmo (tipicamente la convenzione sui nodi dangling) potrebbe essere riprodotto identico in entrambi;
4. si verifica infine che il binario *C* sia *giunto a convergenza*, che il ranking e i valori coincidano e che la somma dei rank sia 1.

Il controllo di convergenza al punto 4 non è ridondante: forzando l'arresto dopo 5 iterazioni il *ranking* dei primi risultati è ancora corretto mentre i valori sono lontani dall'essersi stabilizzati, quindi verificare solo l'ordinamento accetterebbe un risultato quantitativamente sbagliato.

Lo strumento di verifica è stato a sua volta collaudato iniettando un guasto: ricostruendo il CSR da un grafo privato di 457 archi entranti in un nodo, la verifica fallisce a ogni livello, mentre il controllo sulla somma dei rank resta correttamente silenzioso perché il grafo alterato è internamente coerente.

Poiché la matrice densa richiede N^2 elementi, questa verifica è possibile solo sul grafo più piccolo: 386 MiB per **wiki-Vote** contro i 5,6 TB che servirebbero per **web-Google**. È questa la ragione per cui **wiki-Vote** fa parte dell'insieme di test.

3 Risultati sperimentali

3.1 Ambiente di prova

Sistema operativo	Ubuntu 22.04.5 LTS, kernel Linux 6.8
CPU	Intel Core i5-9300H, 4 core fisici / 8 thread, 2,40–4,10 GHz
Cache	L1d 128 KiB, L2 1 MiB, L3 8 MiB
RAM	15 GiB
GPU	NVIDIA GeForce GTX 1050 Ti, 4 GiB, compute capability 6.1, 6 SM
Compilatore	gcc, OpenMP 4.5; CUDA Toolkit 12.8
Opzioni	-std=c11 -Wall -Wextra -O2

Tutti i binari compilano senza alcun avviso.

3.2 Istanze di prova

Sono stati usati quattro grafi reali della collezione SNAP [3], scelti in modo da coprire circa tre ordini di grandezza nel numero di archi (fattore 670× fra il minimo e il massimo).

Tabella 2: Istanze utilizzate.

Grafo	Nodi	Archi	Dangling	max in-deg	CSR
wiki-Vote	7 115	103 689	1 005	457	0,5 MB
web-Google	875 713	5 105 039	136 259	6 326	29,5 MB
web-BerkStan	685 230	7 600 595	4 744	84 208	36,8 MB
soc-LiveJournal1	4 847 571	68 993 773	539 119	13 906	318,7 MB

I due grafi web sollecitano aspetti diversi: **web-BerkStan** ha un singolo *hub* estremo (84 208 archi entranti), mentre **soc-LiveJournal1** ha la distribuzione più pesante nella fascia inter-media (Tabella 1).

3.3 Correttezza

Confronto	Accordo	Esclude
C contro riferimento denso	$4,8 \cdot 10^{-10}$	errori in CSR o nel ciclo di accumulo
NetworkX contro denso	$4,5 \cdot 10^{-12}$	fraintendimenti dell'algoritmo
OpenMP contro sequenziale	$2,1 \cdot 10^{-14}$	race condition
float contro double	$2,2 \cdot 10^{-7}$	perdita di precisione anomala
Somma dei rank (ogni prova)	1,000000	dispersione della massa dangling

Lo scarto relativo fra OpenMP e sequenziale è dovuto unicamente al diverso ordine di somma introdotto dalla riduzione. Lo scarto della versione `float` coincide con l'epsilon di macchina della singola precisione ($1,19 \cdot 10^{-7}$): non si perde quindi nulla oltre al limite intrinseco del formato.

3.4 Scalabilità della versione OpenMP

Ogni configurazione è stata eseguita tre volte; si riporta il *minimo*, perché l'attività di sistema può solo rallentare un'esecuzione, mai accelerarla, e la prova più rapida è quindi la meno disturbata.

Tabella 3: Tempi di esecuzione in secondi (minimo su 3 ripetizioni).

Grafo	seq	1 thr	2 thr	4 thr	8 thr	float 8	speed-up
web-Google	1,326	1,353	0,741	0,459	0,519	0,347	2,89×
web-BerkStan	0,715	0,712	0,400	0,254	0,269	0,214	2,82×
soc-LiveJournal1	11,863	12,442	7,457	5,088	5,014	3,608	2,37×




Figura 1: Scalabilità della versione OpenMP. Il riferimento per lo speed-up è la build sequenziale vera, compilata senza `-fopenmp`. La linea tratteggiata in (a) indica lo speed-up lineare ideale; in (b) l'efficienza del 100 %. Su `web-Google` e `web-BerkStan` il passaggio da 4 a 8 thread *peggiora* il tempo di esecuzione. Figura generata da `tools/plot_results.py` a partire da `results/bench.csv`.

La Figura 1 rende visibile il fenomeno descritto sopra: le tre curve si allontanano dall'andamento lineare già a 2 thread e si appiattiscono fra 4 e 8, con una vera e propria inversione

su due grafi su tre. L'efficienza scende dal 90 % circa a 2 thread al 70 % a 4, fino a circa il 30 % a 8: i thread aggiuntivi non trovano banda di memoria disponibile.

Osservazione principale: il calcolo è memory-bound. Su due grafi su tre l'esecuzione con 8 thread è *più lenta* di quella con 4. Il processore possiede 4 core fisici presentati come 8 thread logici; i due thread che condividono un core condividono anche la via di accesso alla memoria. Poiché il ciclo interno passa la maggior parte del tempo in attesa di letture sparse su `contrib`, i thread aggiuntivi producono contesa anziché capacità di calcolo.

L'efficienza parallela su 4 core è del 60–72%. Questo risultato è il dato più importante dell'analisi: identifica il collo di bottiglia nella *larghezza di banda della memoria*, non nella potenza di calcolo, e costituisce la motivazione quantitativa per il passaggio alla GPU — il cui vantaggio non è tanto il maggior numero di core quanto la banda di memoria sensibilmente superiore.

Nota sull'istanza più piccola. I tempi di `wiki-Vote` non sono riportati in Tabella 3: con durate dell'ordine del millesimo di secondo la dispersione fra ripetizioni della stessa configurazione raggiunge un fattore $51\times$, il che significa che si misurerebbe l'avvio del team di thread e non l'algoritmo. Il grafo resta nell'insieme di prova con il ruolo di riferimento di correttezza (Sezione 2.8).

3.5 Confronto fra le varianti `float` e `double`

La variante in singola precisione è più rapida del 32% su `web-Google` (0,347 s contro 0,459 s), a parità di numero di iterazioni e con ranking identico. Il guadagno è coerente con il dimezzamento dei byte trasferiti per ogni rank, ed è un'ulteriore conferma indiretta della natura memory-bound del calcolo.

Il limite della singola precisione si manifesta sulla soglia di convergenza: su `web-Google` l'errore L_1 non scende sotto $\approx 5 \cdot 10^{-9}$, per cui una tolleranza di 10^{-9} non viene mai raggiunta mentre la doppia precisione converge in 104 iterazioni. Alla tolleranza utilizzata negli esperimenti (10^{-6}) entrambe convergono nello stesso numero di iterazioni.

3.6 Risultati della versione ibrida

[DA COMPLETARE] Sezione da scrivere: tempi della versione CUDA e ibrida, confronto con OpenMP, occupancy, effetto della granularità adattiva, effetto della sovrapposizione fra trasferimenti e calcolo.

4 Valutazioni e osservazioni

4.1 Punti di forza

- **Assenza di sincronizzazione nel nucleo di calcolo.** La scelta del CSR trasposto elimina alla radice le scritture concorrenti, e si trasferisce invariata alla versione CUDA.
- **Riferimento sequenziale onesto.** Sequenziale e parallelo provengono dallo stesso sorgente, il che rende impossibile una divergenza fra le due versioni e non gonfia lo speed-up dichiarato.
- **Verifica indipendente e collaudata.** Tre implementazioni concordano, e lo strumento di verifica è stato validato con un'iniezione di guasto.
- **Riproducibilità.** L'intera campagna sperimentale è riproducibile con un solo comando.

4.2 Punti deboli e limiti

- **Il convertitore non scala oltre le istanze usate.** Il convertitore Python mantiene l'intera edge list in memoria, con un costo di circa 100 byte per arco (6,66 GB misurati su `soc-LiveJournal1`). Un'istanza da un miliardo di archi richiederebbe un convertitore in C con ordinamento esterno.
- **Formato binario non standard.** Il formato `.csr` è specifico del progetto: è velocissimo da caricare, ma non ispezionabile con strumenti esterni. La scelta è stata fatta consapevolmente, privilegiando l'assenza di parsing nel percorso misurato.
- **Dimensione della porzione dinamica non ottimizzata.** Il valore 256 di `schedule(dynamic, 256)` non è stato oggetto di una ricerca sistematica.

4.3 Possibili miglioramenti

- **Gestione out-of-core.** Era prevista in fase di proposta una logica di streaming per grafi eccedenti la memoria della GPU. Le misure hanno mostrato che non è necessaria per le istanze considerate: il grafo più grande occupa 356 MB contro i 4 GB disponibili, e servirebbe un'istanza dell'ordine del miliardo di archi per superare la soglia. Resta un possibile sviluppo futuro, subordinato però alla riscrittura del convertitore.
- **Granularità adattiva sulla GPU.** Le misure di Tabella 1 sono già disponibili ma non ancora sfruttate da alcun kernel.
- **Ricerca sui parametri di scheduling** (politica e dimensione del blocco) e confronto con `guided`.

[DA COMPLETARE] Aggiungere la valutazione personale complessiva una volta completata la fase CUDA.

5 Guida all'uso e riproducibilità

5.1 Requisiti

gcc con supporto OpenMP; CUDA Toolkit per la versione ibrida; Python 3 con `numpy` per la conversione dei dataset, più `networkx` e `scipy` per la sola verifica di correttezza.

5.2 Compilazione

```
| make
```

Produce quattro eseguibili in `build/`: `pagerank_seq` (senza OpenMP), `pagerank_omp`, `pagerank_omp_float` e `csr_info`. Tutti derivano dagli stessi file sorgente.

5.3 Preparazione dei dati

```
| mkdir -p data/snap && cd data/snap  
| for g in wiki-Vote web-Google web-BerkStan soc-LiveJournal1; do  
|     curl -O https://snap.stanford.edu/data/$g.txt.gz && gunzip $g.txt.gz  
| done  
| cd ../../  
| python3 tools/snap_to_csr.py data/snap/web-Google.txt
```

5.4 Esecuzione

```
| ./build/pagerank_omp data/snap/web-Google.csr -i data/snap/web-Google.ids
```

Opzioni: `-d` damping, `-t` tolleranza, `-n` iterazioni massime, `-k` quanti nodi stampare, `-o` salva tutti i rank, `-c` accoda una riga CSV con i dati dell'esecuzione. Il numero di thread si imposta con `OMP_NUM_THREADS`.

5.5 Verifica della correttezza

```
| python3 tools/verify_pagerank.py data/snap/wiki-Vote.txt
```

Termina con stato diverso da zero in caso di discrepanza, e può quindi essere usato come test di regressione.

5.6 Riproduzione degli esperimenti

```
| tools/run_benchmarks.sh
```

Esegue ogni grafo con le varianti sequenziale, OpenMP (1/2/4/8 thread) e float, con tre ripetizioni, e scrive `results/bench.csv` (una riga per esecuzione) e i vettori dei rank completi. Le impostazioni sono sovrascrivibili da ambiente, ad esempio `GRAPHS="wiki-Vote" REPS=1 tools/run_benchmarks.sh`.

5.7 Codice sorgente

Il codice completo, con la cronologia di sviluppo, è disponibile all'indirizzo

<https://github.com/EmanueleCecchia/pagerank-openmp-cuda>

Il repository contiene i sorgenti C, gli strumenti Python di conversione e verifica, lo script della campagna sperimentale e il file `results/bench.csv` con i dati grezzi di tutte le esecuzioni. I dataset e i vettori dei rank non sono versionati per ragioni di dimensione: i primi si ricaricano con i comandi della Sezione 5.3, i secondi si rigenerano con `tools/run_benchmarks.sh`.

Riferimenti bibliografici

- [1] L. Page, S. Brin, R. Motwani, T. Winograd, *The PageRank Citation Ranking: Bringing Order to the Web*, Stanford InfoLab, 1999.
- [2] V. Visali, R. Manimegalai, S. Noor Mahammad, A. Sunitha Nandhini, *Performance Analysis of Parallelized PageRank Algorithm using OpenMP, MPI and CUDA*, ICSSEECC, pp. 44–49, IEEE, 2024.
- [3] J. Leskovec, A. Krevl, *SNAP Datasets: Stanford Large Network Dataset Collection*, <https://snap.stanford.edu/data>, 2014.
- [4] D. B. Kirk, W. W. Hwu, *Programming Massively Parallel Processors*, 3rd ed., Morgan Kaufmann, 2016.
- [5] NVIDIA, *CUDA C++ Programming Guide*.